SVEUČILIŠTE JURJA DOBRILE U PULI

SVEUČILIŠNI DIPLOMSKI STUDIJ RAČUNARSTVO



Matej ABRAMOVIĆ

ANALIZA ALGORITAMA DETEKCIJE RUBOVA TEMELJENIH NA EUKLIDSKOJ UDALJENOSTI S PRIMJENOM U SUSTAVIMA INDUSTRIJSKE VIZUALNE INSPEKCIJE

DIPLOMSKI RAD

JMBAG: 0303090408, redoviti student

Studijski smjer: Računarstvo

Mentor: izv. prof. dr. sc. tech. Marko Kršulja

Komentor: izv. prof. dr. sc. Lovro Liverić

Pula, 17.09.2026. godine

1. UVOD 1
1.1. HIPOTEZA ISTRAŽIVANJA 2
1.2. PREDMET ISTRAŽIVANJA 2
1.3. PROBLEM ISTRAŽIVANJA 2
1.4. CILJEVI RADA 3
1.5. METODOLOGIJA RADA 3
1.6. STRUKTURA RADA 4
2. TEORIJSKE OSNOVE DETEKCIJE RUBOVA 5
2.1. ROBERTS DETEKCIJA RUBOVA 5
2.2. SOBEL DETEKCIJA RUBOVA 6
2.3. PREWITT DETEKCIJA RUBOVA 6
2.4. CANNY DETEKCIJA RUBOVA 6
2.5. DISTANCE TRANSFORM METODE 7
2.6. ULOGA GRADIJENTA I RUBOVA U OBRADI SLIKE 7
3. ANALIZIRANJE ULOGE EUKLIDSKE UDALJENOSTI U OBRADI SLIKA 9
4. IMPLEMENTACIJA ODABRANIH ALGORITAMA 11
4.1. KORIŠTENE PROGRAMSKE BIBLIOTEKE I ORGANIZACIJA KODA 11
4.2. TIJEK RADA ALGORITMA 11
4.3. ZAJEDNIČKA OKOSNICA (EUKLIDSKI REZ RAZINE TEKUĆINE) 13
4.4. LOKALNA PARADIGMA (GRADIJENT BOJE U CIELAB PROSTORU) 13
4.5. GLOBALNA PARADIGMA (K-MEANS SEGMENTACIJA) 14
4.6. VARIJACIJSKA PARADIGMA (CHAN-VESE AKTIVNA KONTURA) 15
5. EKSPERIMENTALNA TESTIRANJA NA RAZLIČITIM SKUPOVIMA SLIKA 17
5.1. SKUP PODATAKA 17
5.2. REFERENTNE VRIJEDNOSTI (GROUND TRUTH) 20
5.3. MJERE USPOREDBE 21
5.4. PRIMJER OUTPUTA ALGORITMA 22
6. USPOREĐIVANJE REZULTATA 23
6.1. UKUPNI REZULTATI 23
6.2. VIZUALNA USPOREDBA NA POJEDINAČNIM SCENAMA 25
6.3. UTJECAJ SLOŽENOSTI SCENE 27
6.4. UTJECAJ OSVJETLJENJA 28

6.5. UTJECAJ PROZIRNOSTI BOCE 29
6.6. ODABIRANJE ALGORITMA ZA NAJBOLJE REZULTATE 29
7. PREDNOSTI I NEDOSTATCI ODABRANIH ALGORITAMA 30
7.1. LOKALNA PARADIGMA (GRADIJENT BOJE) 30
7.2. GLOBALNA PARADIGMA (K-MEANS) 30
7.3. VARIJACIJSKA PARADIGMA (CHAN-VESE) 30
7.4. RGB GRADIJENT (ABLACIJA 30
7.5. ZAJEDNIČKI OSVRT 31
8. MOGUĆNOST PRIMJENE U INDUSTRIJSKIM SUSTAVIMA 32
9. ZAKLJUČAK 33
10. LITERATURA 34
11. POPIS SLIKA 36
12. POPIS TABLICA 37

1. UVOD

Razvoj računalnog vida i digitalne obrade slike posljednjih je desetljeća doveo do značajnog napretka u području automatskog prepoznavanja i analize vizualnih informacija. Trenutno se mnogi suvremeni sustavi, od industrijske automatizacije i sustava kontrole kvalitete pa sve do medicinske dijagnostike i autonomnih sustava, temelje na mogućnosti računala da pouzdano interpretira sadržaj digitalnih slika. Važno je napomenuti da jedan od najvažnijih koraka u takvom procesu predstavlja detekcija rubova, odnosno pronalaženje granica objekata unutar slike. Dobiveni rubovi predstavljaju jednu od temeljnih značajki slike jer omogućuju izdvajanje oblika, struktura i detalja potrebnih za daljnju analizu, klasifikaciju i prepoznavanje objekata. U ovome se radu ta općenita ideja provjerava na konkretnom zadatku određivanja razine tekućine u bocama.

Detekcija rubova tijekom godina razvijala se kroz velik broj algoritama i metoda koje se razlikuju prema načinu određivanja granica objekata. Među najpoznatijim pristupima ističu se Sobelov, Prewittov i Canny algoritam, kao i različite metode temeljene na promjenama intenziteta susjednih piksela. Takvi se algoritmi uspješno primjenjuju u različitim područjima računalnog vida, međutim njihova učinkovitost može biti ograničena u uvjetima prisutnosti šuma, promjenjivog osvjetljenja i složenih tekstura koje su karakteristične za stvarna industrijska okruženja.

Zbog toga predlaže se euklidska udaljenost kao jedan od koncepata koji se može primjenjivati u obradi slika i koji potencijalno može doprinijeti povećanju preciznosti detekcije rubova. Primjena euklidske udaljenosti omogućuje određivanje razlika između susjednih piksela te pronalaženje prijelaza između različitih područja slike. Osim u analizi intenziteta sivih tonova, euklidska udaljenost može se primjenjivati i u drugim prostorima boja, poput RGB i LAB prostora, čime se može omogućiti preciznije određivanje granica objekata i povećati otpornost algoritama na različite smetnje prisutne u stvarnim uvjetima rada.

U ovom radu pozornost će biti usmjerena upravo na algoritme koji koriste euklidsku udaljenost kao osnovnu ili pomoćnu metriku za detekciju rubova. Naravno, analizirat će se i klasične metode poput Sobelovog i Prewittovog algoritma, Canny algoritma te različiti pristupi koji se temelje na razlikama intenziteta, udaljenostima u prostoru boja i metodama Distance Transform. Cilj analize navedenih metoda jest njihova usporedba s algoritmima koji se nalaze u fokusu ovoga rada.

Poseban naglasak stavit će se na praktični dio istraživanja i eksperimentalnu analizu. Odabrani algoritmi bit će implementirani u programskom jeziku Python, a njihova učinkovitost ispitivat će se na različitim skupovima slika karakterističnim za industrijske sustave vizualne inspekcije. Pri tome se praktični dio usmjerava na jedan konkretan i reprezentativan zadatak industrijske vizualne inspekcije, određivanje razine punjenja boca na temelju fotografija. Takve fotografije sadrže promjenjivo osvjetljenje, prozirne i obojene materijale te složene pozadine, zbog čega predstavljaju vrlo pogodno okruženje za ispitivanje učinkovitosti algoritama detekcije rubova i granica objekata.

Prilikom analize rezultata koristit će se različite metrike za procjenu kvalitete detekcije. Posebna pozornost posvetit će se preciznosti detekcije, broju lažno detektiranih rubova te otpornosti algoritama na promjene osvjetljenja i složenost scene. Na temelju dobivenih rezultata usporedit će se prednosti i nedostaci pojedinih pristupa te procijeniti njihove mogućnosti primjene u industrijskim sustavima računalnog vida.

Osim teorijskog pregleda temeljnih koncepata detekcije rubova i uloge euklidske udaljenosti u obradi slike, rad će obuhvatiti implementaciju odabranih algoritama, eksperimentalna testiranja i analizu dobivenih rezultata. Poseban interes bit će usmjeren na usporedbu različitih pristupa u različitim uvjetima snimanja, poput promjena osvjetljenja i složenosti scene. Zaključno, nastojat će se utvrditi u kojoj mjeri primjena euklidske udaljenosti može doprinijeti preciznijoj i robusnijoj detekciji rubova te koje su mogućnosti njezine primjene u suvremenim industrijskim sustavima.

1.1. HIPOTEZA ISTRAŽIVANJA

Temeljna hipoteza rada polazi od pretpostavke da primjena euklidske udaljenosti kao osnovne ili pomoćne metrike u algoritmima za detekciju rubova može povećati preciznost i robusnost prepoznavanja granica objekata u odnosu na klasične metode detekcije rubova. Posebno se pretpostavlja da će takav pristup pokazati bolje rezultate u uvjetima prisutnosti šuma, promjenjivog osvjetljenja i složenih tekstura karakterističnih za industrijske sustave vizualne inspekcije.

1.2. PREDMET ISTRAŽIVANJA

Predmet istraživanja ovoga rada predstavljaju algoritmi za detekciju rubova u digitalnim slikama, s posebnim naglaskom na metode koje koriste euklidsku udaljenost kao osnovnu ili pomoćnu metriku za određivanje granica objekata. Osim teorijskih obilježja takvih algoritama, ispitat će se i njihove mogućnosti primjene u sustavima industrijske vizualne inspekcije.

1.3. PROBLEM ISTRAŽIVANJA

Problem istraživanja proizlazi iz činjenice da postojeće metode detekcije rubova mogu pokazivati smanjenu učinkovitost u uvjetima povećane razine šuma, promjenjivog osvjetljenja i složenih tekstura koje su karakteristične za industrijska okruženja. Stoga se postavlja pitanje u kojoj mjeri primjena euklidske udaljenosti može unaprijediti proces detekcije rubova i omogućiti preciznije izdvajanje granica objekata u usporedbi s klasičnim algoritmima.

1.4. CILJEVI RADA

Glavni cilj rada jest analizirati mogućnosti primjene euklidske udaljenosti u algoritmima za detekciju rubova te procijeniti njezin doprinos povećanju preciznosti i robusnosti sustava računalnog vida namijenjenih industrijskoj vizualnoj inspekciji.

Kako bi se ostvario navedeni cilj, definirani su sljedeći specifični ciljevi:

- analizirati teorijske osnove digitalne obrade slike i detekcije rubova
- proučiti matematičku osnovu euklidske udaljenosti i njezinu primjenu u obradi slike
- analizirati klasične algoritme za detekciju rubova i metode koje koriste euklidsku udaljenost
- implementirati odabrane algoritme u programskom jeziku Python
- provesti eksperimentalna ispitivanja na različitim skupovima industrijskih slika
- usporediti rezultate primjenom odgovarajućih metrika kvalitete
- odrediti prednosti i nedostatke pojedinih pristupa te procijeniti mogućnosti njihove primjene u sustavima industrijske vizualne inspekcije

1.5. METODOLOGIJA RADA

Pri izradi rada koristit će se nekoliko znanstvenih metoda. Metoda analize i sinteze primijenit će se pri proučavanju dostupne literature iz područja digitalne obrade slike, računalnog vida i detekcije rubova, pri čemu će se postojeće spoznaje povezati u cjelovit teorijski okvir istraživanja.

Komparativna metoda koristit će se pri usporedbi klasičnih algoritama detekcije rubova i algoritama koji koriste euklidsku udaljenost. Uspoređivat će se njihove karakteristike, prednosti i ograničenja te kvaliteta dobivenih rezultata.

Eksperimentalna metoda primijenit će se za implementaciju odabranih algoritama u programskom jeziku Python te za provođenje ispitivanja na različitim skupovima slika karakterističnim za industrijska okruženja. Posebna pozornost posvetit će se utjecaju šuma, promjenama osvjetljenja i složenim teksturama.

Statistička metoda koristit će se pri obradi i interpretaciji rezultata dobivenih eksperimentalnim ispitivanjima. Na temelju različitih metrika procjenjivat će se preciznost detekcije, broj lažno detektiranih rubova te otpornost pojedinih algoritama na prisutnost smetnji.

1.6. STRUKTURA RADA

Rad je podijeljen u devet poglavlja.

U prvom poglavlju prikazane su osnovne značajke računalnog vida i digitalne obrade slike te su definirani hipoteza, predmet i problem istraživanja, ciljevi rada, metodologija istraživanja i struktura rada.

U drugom poglavlju obrađuju se teorijske osnove detekcije rubova i prikazuju temeljni koncepti te značaj detekcije rubova u području računalnog vida.

Treće poglavlje posvećeno je analizi uloge euklidske udaljenosti u obradi slika te mogućnostima njezine primjene u određivanju granica objekata. Upravo je euklidska udaljenost, zbog svoje jednostavnosti i jasne geometrijske interpretacije, odabrana kao zajednička okosnica svih algoritama razvijenih u ovome radu.

U četvrtom poglavlju prikazana je implementacija odabranih algoritama za detekciju rubova u programskom jeziku Python.

Peto poglavlje obuhvaća eksperimentalna ispitivanja provedena na vlastitom skupu fotografija boca.

U šestom poglavlju prikazana je usporedba dobivenih rezultata primjenom odgovarajućih kriterija i metrika procjene kvalitete detekcije.

Sedmo poglavlje donosi analizu prednosti i nedostataka promatranih algoritama te njihovu međusobnu usporedbu.

U osmom poglavlju razmatraju se mogućnosti primjene analiziranih algoritama u sustavima industrijske vizualne inspekcije.

U posljednjem, devetom poglavlju, iznose se zaključna razmatranja te se prikazuju najvažniji rezultati provedenog istraživanja i mogućnosti daljnjeg razvoja predmetnog područja.

2. TEORIJSKE OSNOVE DETEKCIJE RUBOVA

Rub je u digitalnoj slici mjesto na kojem se svjetlina ili boja naglo mijenja, a takva promjena gotovo uvijek označava neku stvarnu granicu u prizoru, primjerice obris predmeta, spoj dviju ploha ili prijelaz između predmeta i pozadine. Dobar primjer daje upravo problem kojim se ovaj rad bavi, jer se površina tekućine u boci na slici očituje kao vodoravan rub, odnosno kao nagao prijelaz između svjetlijega praznog dijela i tamnijega ispunjenog dijela boce. Prepoznavanjem takvih rubova računalo iz sirove slike izdvaja upravo one podatke koji nose značenje.

Detekcija rubova stoga je jedan od najvažnijih i najranijih koraka u obradi slike. Slika je za računalo tek golema tablica brojeva u kojoj svaki broj opisuje svjetlinu ili boju jednoga piksela, a takvih brojeva na jednoj fotografiji ima više milijuna. Detekcija rubova tu golemu količinu podataka sažima u mnogo manji skup crta i granica koje zadržavaju glavninu strukturne informacije o prizoru. Time se olakšavaju i ubrzavaju sve kasnije faze, od izdvajanja objekata (segmentacije) i prepoznavanja oblika do mjerenja i klasifikacije. Jednostavno rečeno, umjesto da istodobno razmatra svaki piksel, računalo najprije pronađe obrise i dalje radi samo s njima.

Rub se u pravilu pronalazi mjerenjem promjene svjetline ili boje između susjednih piksela, odnosno računanjem gradijenta slike. Ondje gdje je promjena velika, gradijent je jak i vjerojatno se radi o rubu, a ondje gdje je slika glatka, gradijent je slab. Na toj se ideji temelji većina klasičnih operatora, koji se međusobno razlikuju po tome kako mjere promjenu i koliko su otporni na šum. U ovom se poglavlju redom opisuju najpoznatiji klasični pristupi, Robertsov, Sobelov, Prewittov i Cannyjev operator, potom metode transformacije udaljenosti (Distance Transform), a naposljetku i uloga gradijenta i rubova u cjelokupnoj obradi slike. Time se postavlja teorijski temelj na koji se u sljedećim poglavljima nadovezuje euklidska udaljenost kao zajednička mjera svih razvijenih algoritama..

2.1. ROBERTS DETEKCIJA RUBOVA

U Roberts detekciji rubova koristi se Roberts Cross operator koji se sastoji od para 2x2 konvolucijske matrice. Te matrice su [[1, 0], [0, -1]] i [[0, 1], [-1, 0]]. Roberts Cross operator izrađuje jednostavno i brzo 2D prostorno gradijentno mjerenje na samu sliku. Tako filtrira regije visoke prostorne frekvencije koje često prikazuju rubove. U njegovoj upotrebi najčešće se koriste slike u spektru sive boje (grayscale slike) kao ulazna slika operatoru [3]. Iako je što se tiče kompleksnosti algoritma naspram većine algoritama koji će se obraditi vrlo osnovan, on svejedno pruža kvalitetnu sliku u idealnim uvjetima. No, u noćnim i sobnim uvjetima gubi oštrinu te daje samo generalni opis objekata sa slike.

2.2. SOBEL DETEKCIJA RUBOVA

Sobel detekcija rubova ima bolji efekt na procesuiranje slika s više sivih gradijenata i šumom. Također se radi o par konvolucijskih jezgri. Te matrice su [[-1, 0, +1], [-2, 0, +2], [1, 0, +1]] i [[+1, +2, +1], [0, 0, 0], [-1, -2, -1]] [5]. Kao što se može vidjeti i u prethodnom operateru, jedna jezgra je samo rotirana za 90 stupnjeva. Zbog svoje jednostavnosti nije vrlo točan u pronalasku pravih rubova u slici. Sobel operater je zato pogodan za pronalaženje blijedih tj. glatkih rubova. Ukoliko je rub na slici veći od jednog piksela, kvaliteta rubova na slici drastično pada. Koristi se kao brz i efikasan alat, no ne zbog svoje kvalitete. Zbog svoje jednostavnosti brzo izrađuje obrađene slike. Vidljivo je da se u slikama lošijeg osvjetljenja i visoke razine šuma dobro snalazi i dobro označava rubove. U slikama visoke kvalitete i oštrijih rubova stvara predebel rub i spaja par rubova u jedan.

2.3. PREWITT DETEKCIJA RUBOVA

Ova metoda je najčešće korištena kao detekcija rubova u horizontalnim i vertikalnim linijama. Rubovi su u ovom slučaju kalkulirani koristeći razliku između piksela u slici. Prewitt operater radi sa derivacijskim matricama [4]. Te matrice su [[1, 1, 1],[0, 0, 0],[-1, -1, -1]] i [-1, 0, 1],[-1, 0, 1],[-1, 0, 1]]. Kao što se može vidjeti i u prethodnim operaterima, jedna jezgra je samo rotirana za 90 stupnjeva. Nije izrazito točan, no daje dobre rezultate u detekciji rubova. U lošem osvjetljenju daje zadovoljavajuće rezultate, a u dobrom osvjetljenju ti se razultati još i poboljšavaju.

2.4. CANNY DETEKCIJA RUBOVA

John F. Canny je izumitelj opće prihvaćeno najbolje detekcije rubova. Još 1986. je želio kreirati najefikasniji i najrafiniraniji oblik detekcije rubova. Ta metoda je vrlo otporna na šum jer kalkulira prethodno spomenute prave blijede rubove. Rubove koje većina algoritama zanemari kao šum ili nedovoljno čistima za uporabu. Dva različita praga kreiraju čiste i jasne rubove te blijede i mutne rubove. Ukoliko algoritam razazna spoj između jasnog i mutnog ruba, tada se mutni rub pripaja jasnom i tvori se vrlo kvalitetna slika. Canny operator je vrlo snažan i kompleksan operator koji izlučuje karakteristike slike, tj. objekata u njoj bez izmjene i izobličavanja slike [2].

Njegove kalkulacije ispunjavaju tri različita kriterija: vrlo niski prag pogreške, lokalizirani rubovi i težnja da se izračuna prikaz jednog ruba u točke odaziva ruba. Vrlo niski prag pogreške govori da je količina detalja zadovoljavajuća i u mnogo iteracija ne izobličuje sliku te prikazuje rubove vjerno originalnoj slici. Lokalizirani rubovi predstavljaju čiste i jasne rubove. Ti rubovi nisu zamućeni i ukaljani lažnim rubovima. Težnja da se izračuna prikaz jednog ruba u točke odaziva ruba znači da ne kalkulira pogrešno dva ili više ruba u segmentu slike u kojem se nalazi samo jedan. U tom dijelu znači da je otporan na šum. Zbog navedenih činjenica, Canny detekcija rubova se smatra optimalnom detekcijom rubova.

2.5. DISTANCE TRANSFORM METODE

Distance Transform (DT) metode predstavljaju postupak pretvorbe binarne slike u sliku udaljenosti, gdje svaki piksel u pozadini dobiva vrijednost koja odgovara njegovoj najkraćoj euklidskoj ili geodetskoj udaljenosti do najbližeg rubnog piksela objekta. Ove metode se često koriste kao pripremni korak u morfološkim operacijama, skeletonizaciji i segmentaciji objekata. Za razliku od detekcije rubova koja naglašava granice, Distance Transform naglašava unutrašnjost objekata stvarajući gradijentnu mapu koja je najviša u središtu oblika. Iako su računalno zahtjevnije od jednostavnih konvolucijskih operatora, moderne implementacije poput Chandler-Black ili Felzenszwalb-Huttenlocher algoritama omogućuju linearnu složenost [12].

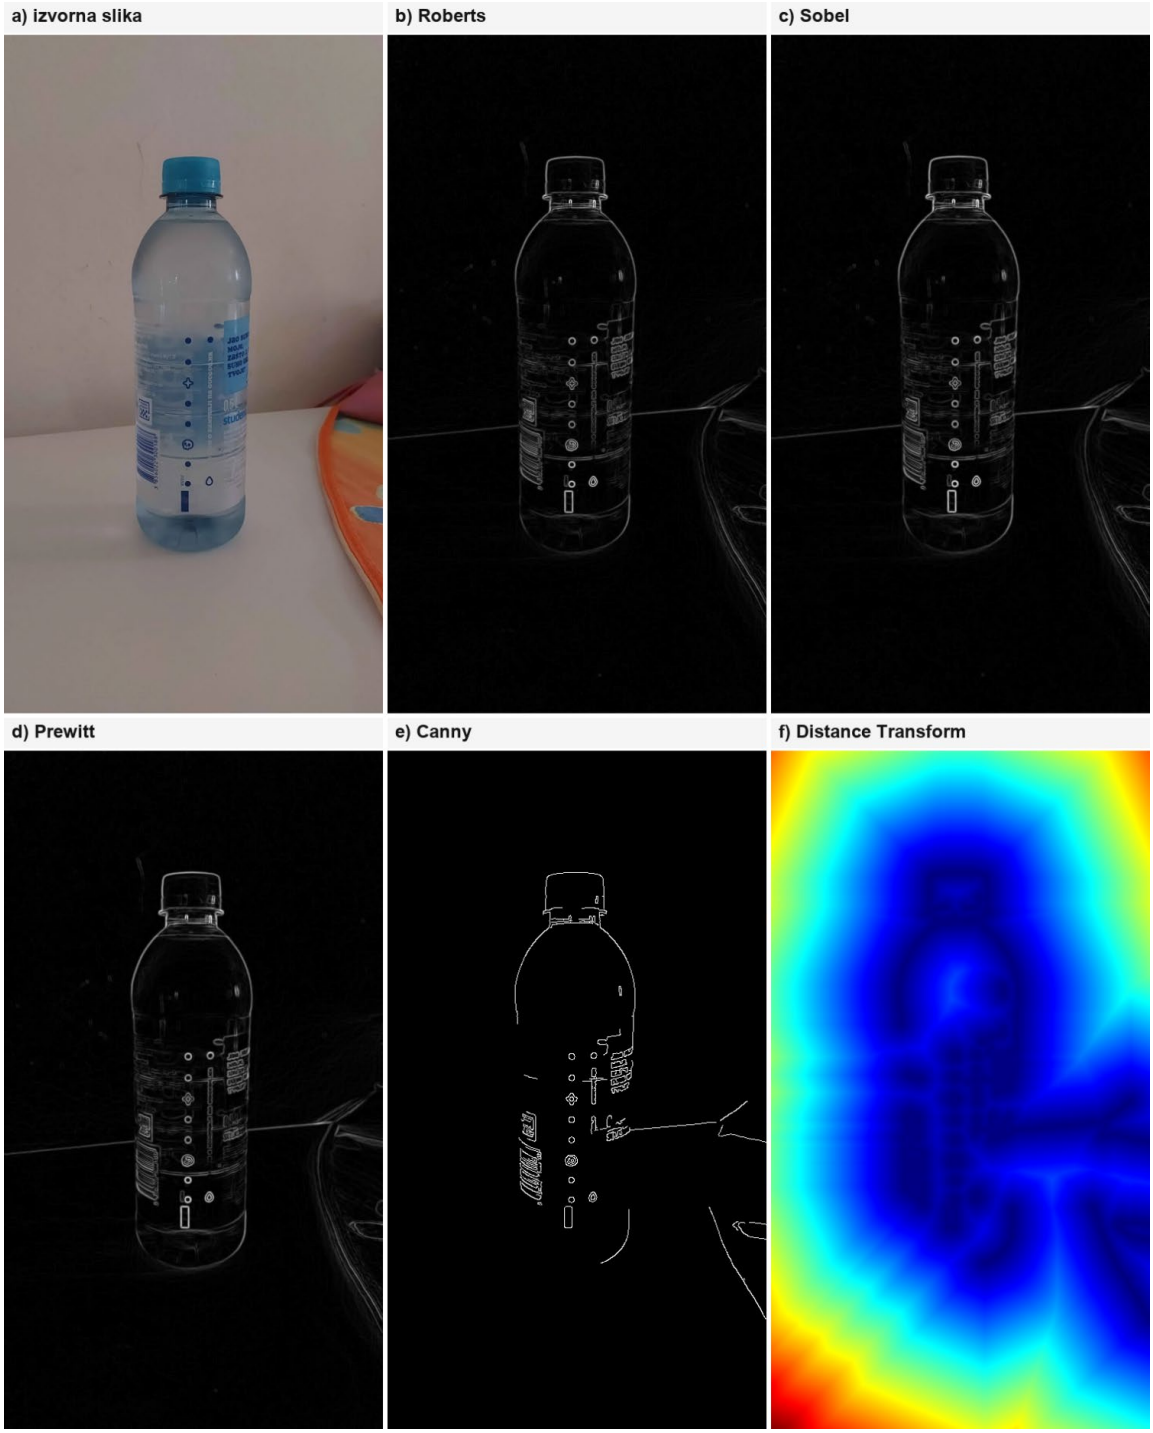
Ove metode su posebno korisne u analizi oblika i računalnoj anatomiji, gdje je potrebno kvantificirati debljinu ili zakrivljenost struktura. U uvjetima visokog šuma, Distance Transform može biti nestabilna jer binarna priroda ulazne slike zahtijeva pouzdanu segmentaciju, stoga se često kombinira s Canny detekcijom rubova za generiranje čistih binarnih maski.

2.6. ULOGA GRADIJENTA I RUBOVA U OBRADI SLIKE

Gradijent i rubovi čine temeljne koncepte računalnog vida jer predstavljaju prvu razinu apstrakcije koja smanjuje količinu podataka uz zadržavanje strukturnih informacija. Gradijent slike, izračunat kao prva derivacija intenziteta piksela u x i y smjeru, ukazuje na smjer i brzinu promjene svjetline, pri čemu maksimumi gradijenta označavaju potencijalne rubove. Rubovi su kritični za višerazinsku obradu jer omogućuju segmentaciju objekata, detekciju oblika, rekonstrukciju 3D scena iz 2D projekcija te ekstrakciju značajki za strojno učenje. Bez rubova, sustavi za prepoznavanje uzoraka, autonomnu vožnju ili medicinsku dijagnostiku ne bi mogli razlučiti objekte od pozadine [1], [6].

Kvaliteta detekcije rubova izravno utječe na sve naredne faze obrade. Loše lokalizirani rubovi uzrokuju pogrešnu segmentaciju, dok pretjerano debeli rubovi spajaju susjedne objekte. Upravo zato se u praksi često koristi hibridni pristup: prvo se primijeni Canny operator za optimalnu detekciju, zatim Distance Transform pristup za analizu unutarnje strukture, a potom se rezultati kombiniraju s morfološkim operacijama za poboljšanje kvalitete konačne obrade. Gradijentne informacije također su ključne u algoritmima za poravnavanje slika, optički tok i praćenje objekata u video sekvencama, gdje rubovi služe kao stabilne referentne točke čak i pri promjenama osvjetljenja.

Radi vizualne usporedbe opisanih pristupa, Slika 1 prikazuje rezultate klasičnih operatora detekcije rubova (Robertsova, Sobelova, Prewittova i Cannyjeva metoda) te transformacije udaljenosti, primijenjenih na istu fotografiju boce. Već se na prvi pogled uočava razlika u debljini i čistoći dobivenih rubova, u skladu s teorijskim svojstvima svake metode.



Slika 1. *Usporedba klasičnih operatora detekcije rubova (Roberts, Sobel, Prewitt, Canny) i transformacije udaljenosti na uzorku boce (Izvor: obrada autora)*

3. ANALIZIRANJE ULOGE EUKLIDSKE UDALJENOSTI U OBRADI SLIKA

Euklidska udaljenost predstavlja temeljnu metriku u obradi slika koja omogućuje kvantitativno uspoređivanje piksela, regija i cjelokupnih slika. U svom osnovnom obliku, euklidska udaljenost između dviju točaka u n-dimenzionalnom prostoru definira se kao korijen zbroja kvadrata razlika po svim koordinatama. Za dvije točke $A(x_1, y_1)$ i $B(x_2, y_2)$ u 2D prostoru, formula glasi:

$$*d*(A, B) = \sqrt{[(x_2 - x_1)^2 + (y_2 - y_1)^2]}$$

U kontekstu obrade slika, ova se metrika proširuje na višedimenzionalne prostore boja gdje svaka dimenzija predstavlja jednu komponentu boje. Za RGB prostor boja, euklidska udaljenost između dva piksela s komponentama (R_1, G_1, B_1) i (R_2, G_2, B_2) računa se prema formuli:

$$*d*(p_1, p_2) = \sqrt{[(R_2 - R_1)^2 + (G_2 - G_1)^2 + (B_2 - B_1)^2]}$$

Ova metrika omogućuje precizno mjerenje razlike boja između piksela, gdje manja udaljenost označava veću sličnost boja, a veća udaljenost ukazuje na značajnije kromatske razlike. U RGB prostoru, euklidska udaljenost podrazumijeva jednakovrijednu težinu svim komponentama boja, što predstavlja njezinu glavnu prednost ali i ograničenje jer ljudski vid nije jednako osjetljiv na sve valne duljine svjetlosti.

Primjena euklidske udaljenosti u obradi slika je višestruka. U segmentaciji slika koristi se za grupiranje piksela sličnih boja u klastere gdje se pikseli dodjeljuju najbližem centroidu na temelju minimalne (kvadrirane) euklidske udaljenosti, što je temelj K-means algoritmu [9], [10]. Centroid klastera se u ovom pristupu računa kao aritmetička sredina piksela upravo zato što se minimizira zbroj kvadrata euklidskih udaljenosti unutar klastera. U detekciji rubova, euklidska udaljenost u prostoru boja može se koristiti za pronalaženje oštrih prijelaza između različitih obojenih regija, iako se u praksi za pouzdaniju detekciju rubova u obojenim slikama češće koriste sofisticiraniji multikanalni gradijentni operatori (npr. Di Zenzov pristup [8]), budući da jednostavna euklidska udaljenost nasljeđuje ista ograničenja kao i pri usporedbi pojedinačnih piksela, što znači jednaku težinu svih kanala boje i neosjetljivost na percepciju boje. U Content-Based Image Retrieval (CBIR) sustavima, euklidska udaljenost između histograma boja ili vektora značajki omogućuje pretraživanje sličnih slika u velikim bazama podataka.

Osim RGB prostora, euklidska udaljenost primjenjuje se i u drugim prostorima boja poput CIELAB i CIELUV, gdje je prostor dizajniran tako da euklidska udaljenost bolje korelira s perceptivnom razlikom boja koju opaža ljudsko oko. U CIELAB prostoru, formula ostaje matematički ista, ali komponente L* (svjetlina), a* (crveno-zeleno) i b* (žuto-plavo) osiguravaju veću perceptivnu ujednačenost prostora.

Nedostatak euklidske udaljenosti u obradi slika ogleda se u njezinoj osjetljivosti na skaliranje, dok je istovremeno invarijantna na translaciju i rotaciju. Dakle, rotacija predstavlja ortogonalnu transformaciju koja ne mijenja udaljenosti između točaka. Ta invarijantnost na rotaciju može biti prednost u nekim primjenama, ali istovremeno euklidska udaljenost ne uzima u obzir korelacije između dimenzija. U prostorima boja gdje komponente nisu nezavisne, poput HSV (Hue, Saturation, Value) prostora, euklidska udaljenost daje pogrešne rezultate jer nijansa (hue) ima cirkularnu prirodu, ta razlika između 0° i 360° iznosi 0°, dok euklidska udaljenost to ne prepoznaje. Stoga se u takvim slučajevima koriste prilagođene metrike ili se prostor boja transformira u perceptivno uniformniji oblik prije primjene euklidske udaljenosti.

Zbog svoje matematičke jednostavnosti i računalne efikasnosti, euklidska udaljenost ostaje najčešće korištena metrika u obradi slika, posebno u algoritmima za uspoređivanje blokova piksela kod kompresije slika, u algoritmima za pronalaženje odgovarajućih točaka kod stereo vida te u dubokom učenju gdje se koristi kao funkcija gubitka za mjerenje razlike između generirane i stvarne slike. Iako su razvijene složenije metrike poput Mahalanobisove udaljenosti koja uzima u obzir varijabilnu strukturu podataka, euklidska udaljenost i dalje predstavlja zlatni standard zbog svoje intuitivne geometrijske interpretacije i široke podrške u programskim knjižnicama za obradu slika.

4. IMPLEMENTACIJA ODABRANIH ALGORITAMA

Sustav je u cijelosti implementiran u programskom jeziku Python, a cilj mu je da na temelju obične fotografije boce samostalno odredi tri stvari: gdje se boca nalazi na slici (okvir i obris boce) te do koje je visine ispunjena tekućinom. Sve tri navedene zadaće svode se na isti temeljni koncept opisan u prethodnom poglavlju, euklidsku udaljenost, samo primijenjenu na tri različita načina. Time se u praksi provjerava može li jedna jednostavna i intuitivna mjera poslužiti kao okosnica cijelog postupka detekcije rubova i granica objekata.

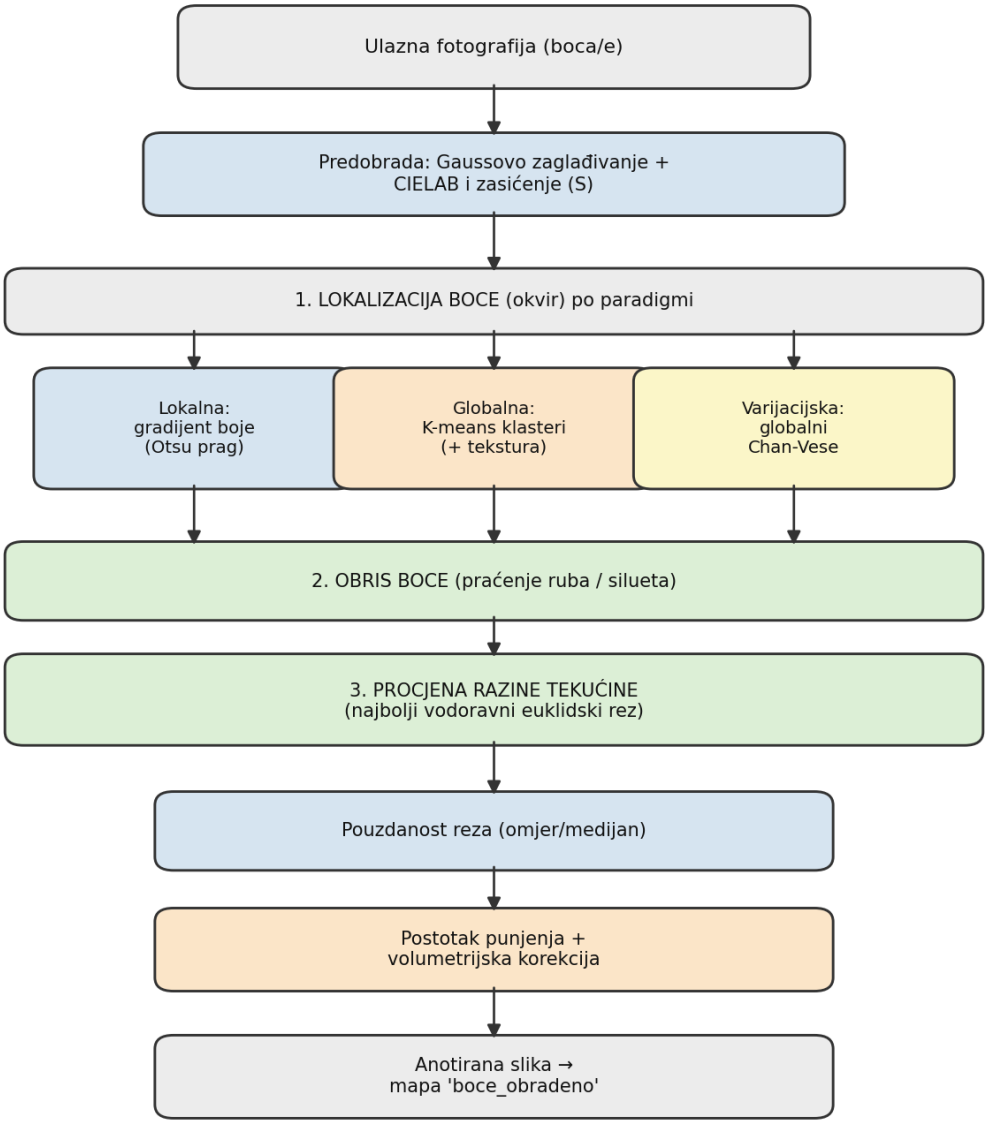
4.1. KORIŠTENE PROGRAMSKE BIBLIOTEKE I ORGANIZACIJA KODA

Za izradu sustava korištene su tri ustaljene biblioteke otvorenog koda. OpenCV (Open Source Computer Vision Library) [13], [20] glavna je biblioteka za obradu slike te se koristi za učitavanje i spremanje slika, pretvorbu između prostora boja (primjerice iz BGR u CIELAB ili HSV), Gaussovo zaglađivanje, Otsu pragiranje, K-means klasteriranje i pronalaženje kontura. NumPy [14] je biblioteka za rad s višedimenzionalnim poljima i omogućuje da se operacije nad milijunima piksela izvedu odjednom (vektorizirano), bez sporih petlji. Upravo se pomoću NumPy-ja euklidska udaljenost računa nad cijelom slikom u jednom koraku. Matplotlib je korišten za izradu grafičkih prikaza rezultata evaluacije.

Programski kod organiziran je u više cjelina radi preglednosti i lakšeg održavanja. Glavna skripta učitava slike iz mape i nudi izbornik za pokretanje pojedinog algoritma. Zasebna mapa sadrži četiri izvedbe algoritama (po jednu za svaku paradigmu te ablacijsku RGB varijantu) i zajednički modul u kojem se nalaze funkcije koje svi algoritmi dijele, a to su učitavanje slike, geometrijski filtri oblika boce, traženje granice tekućine i iscrtavanje rezultata. Posebna mapa sadrži skripte za ručno označavanje referentnih vrijednosti i za mjerenje točnosti algoritama. Ovakva podjela osigurava da su tri paradigme jasno odvojene, što je i jedan od ciljeva rada. Radi ponovljivosti rezultata, nasumični postupci poput K-means klasteriranja koriste unaprijed zadano sjeme, pa svako pokretanje nad istom slikom daje jednak rezultat.

4.2. TIJEK RADA ALGORITMA

Bez obzira na paradigmu, svaki algoritam prolazi kroz isti niz koraka prikazan na dijagramu toka (Slika 2). Nakon učitavanja, slika se najprije predobrađuje, odnosno blago se zaglađuje Gaussovim filtrom kako bi se smanjio utjecaj šuma i sitnih detalja, a zatim se pretvara u CIELAB prostor boja uz dodatnu komponentu zasićenja. U prvom se koraku boca lokalizira, odnosno pronalazi se pravokutni okvir oko svake boce na slici. U drugom se koraku određuje obris (silueta) boce unutar tog okvira. U trećem, najvažnijem koraku procjenjuje se razina tekućine, pri čemu se traži vodoravna granica između praznoga (gornjeg) i ispunjenog (donjeg) dijela boce. Budući da je boca trodimenzionalan i zaobljen objekt, granica nije nužno savršeno ravna crta, pa se širina boce dijeli na više stupaca i u svakom se stupcu granica traži zasebno.



Slika 2. *Dijagram toka algoritma za detekciju razine tekućine (Izvor: obrada autora)*

Uz procjenu razine, svaki algoritam izračunava i pouzdanost svoje procjene. Pouzdanost je definirana kao omjer ocjene najboljeg pronađenog reza i medijana ocjena svih razmatranih rezova; kada je taj omjer blizak jedinici, to znači da nijedan rez nije uvjerljiviji od prosječnoga, odnosno da u boci nema jasne granice boje (primjerice kod posve prozirne boce ili boce koja je gotovo prazna). Takva se procjena označava kao nepouzdana. Na kraju se postotak punjenja korigira s obzirom na zaobljeni oblik boce (volumetrijska korekcija), a rezultat se iscrtava na sliku i sprema u izlaznu mapu.

4.3. ZAJEDNIČKA OKOSNICA (EUKLIDSKI REZ RAZINE TEKUĆINE)

Središnji dio sve tri paradigme jest pronalaženje retka koji najbolje dijeli bocu na gornji i donji dio. Umjesto traženja najvećeg skoka između dvaju susjednih redaka (što je osjetljivo na šum, odsjaj ili mrlju), koristi se globalno najbolji rez: za svaki mogući redak izračunava se koliko su različite prosječne vrijednosti boje gornje i donje skupine piksela. Ta se različitost mjeri u euklidskom smislu, kao kvadrat udaljenosti srednjih vrijednosti dviju skupina, podijeljen s raspršenjem unutar skupina (tzv. Fisherov omjer). Granica tekućine određuje se kao redak s najvećom takvom ocjenom, odnosno kao mjesto najizraženijega i najdosljednijeg prijelaza boje. Jednostavno rečeno, algoritam traži crtu iznad koje su pikseli međusobno slični (primjerice prazan, svijetli dio) i ispod koje su pikseli međusobno slični (primjerice obojena tekućina), a te se dvije skupine međusobno što više razlikuju. U pojednostavljenom obliku taj se postupak svodi na sljedeći isječak koda:

```
# za svaki moguci redak podijeli stupac na gornju i donju skupinu piksela
best_score, best_row = 0.0, lo
for r in range(lo, hi):
    gornja, donja = values[:r], values[r:]
    m1, m2 = gornja.mean(0), donja.mean(0)                    # prosjecne boje skupina
    between = len(gornja)*len(donja) * ((m1 - m2) ** 2).sum() # razdvojenost (euklidski)
    within  = ((gornja - m1)**2).sum() + ((donja - m2)**2).sum()  # rasprsenje unutar
skupina
    score = between / (within + 1e-9)                         # Fisherov omjer
    if score > best_score:
        best_score, best_row = score, r
# best_row = granica tekucine (najjaci i najdosljedniji prijelaz boje)
```

Ono po čemu se tri paradigme razlikuju jest ono što se u tom rezu uspoređuje: kod prve paradigme to je gradijent boje, kod druge pripadnost klasteru, a kod treće odstupanje od prosjeka regije. U nastavku se svaka paradigma opisuje zasebno, uz najvažniji isječak programskog koda koji prikazuje kako se u njoj koristi euklidska udaljenost.

4.4. LOKALNA PARADIGMA (GRADIJENT BOJE U CIELAB PROSTORU)

Prva paradigma euklidsku udaljenost računa između susjednih piksela. Za svaki se piksel gleda koliko se njegova boja razlikuje od boje piksela lijevo, desno, gore i dolje; što je ta razlika (euklidska udaljenost u prostoru boja) veća, to je vjerojatnije da se ondje nalazi rub. Skup svih tih vrijednosti tvori kartu rubova, odnosno magnitudu gradijenta. Karta se zatim Otsu metodom [7] pretvara u crno-bijelu (binarnu) sliku iz koje se geometrijskim filtrima izdvajaju uski, uspravni oblici nalik boci. Računanje se izvodi u CIELAB prostoru boja jer je on perceptivno ujednačen, odnosno euklidska udaljenost u njemu bolje odgovara razlici boja koju opaža ljudsko oko i manje je osjetljiva na promjene osvjetljenja nego u RGB prostoru. Ključni dio koda prikazan je u nastavku:

```
def edge_map(image_bgr):
    # pretvorba u CIELAB prostor boja (perceptivno ujednacen)
    lab = cv2.cvtColor(image_bgr, cv2.COLOR_BGR2LAB).astype(np.float64)

    # euklidska udaljenost boje SUSJEDNIH piksela (lijevo-desno i gore-dolje)
    diff_x = lab[:, 2:, :] - lab[:, :-2, :]
    diff_y = lab[2:, :, :] - lab[:-2, :, :]
    gx = np.linalg.norm(diff_x, axis=2)   # || razlika boje || po x-osi
    gy = np.linalg.norm(diff_y, axis=2)   # || razlika boje || po y-osi

    # jakost ruba = magnituda gradijenta boje
    magnitude = np.sqrt(gx ** 2 + gy ** 2)
    return (magnitude / magnitude.max() * 255).astype(np.uint8)
```

Funkcija np.linalg.norm računa upravo euklidsku normu vektora razlike boje po svakom pikselu, čime se dobiva jakost promjene boje. Ista je metoda izvedena i u ablacijskoj varijanti koja radi u RGB prostoru boja umjesto u CIELAB-u; ta varijanta služi isključivo za usporedbu dvaju prostora boja unutar iste (gradijentne) metode, a njezini se rezultati razmatraju u šestom poglavlju.

4.5. GLOBALNA PARADIGMA (K-MEANS SEGMENTACIJA)

Druga paradigma euklidsku udaljenost računa između piksela i središta (centroida) klastera. Algoritam K-means dijeli sve piksele slike u unaprijed zadan broj skupina (klastera) tako da svaki piksel pripadne onom klasteru čijem je prosjeku boje najbliži po euklidskoj udaljenosti. Pikseli slične boje tako završavaju u istom klasteru i tvore povezane regije, a rub se definira kao granica između dvaju različitih klastera. Prostor značajki čine komponente CIELAB boje i zasićenje, a pri lokalizaciji se dodaju i ponderirane prostorne koordinate kako bi se dvije boce iste boje na različitim mjestima razdvojile u zasebne regije. Osnovna izvedba klasteriranja prikazana je u nastavku:

```
def kmeans_cluster(feature_map, k):
    # svaki piksel = vektor znacajki (L, a, b, zasicenje)
    samples = feature_map.reshape(-1, feature_map.shape[-1]).astype(np.float32)
    # K-means dodjeljuje piksel klasteru NAJBLIZEM po euklidskoj udaljenosti
    _, labels, centers = cv2.kmeans(
        samples, k, None, criteria, 4, cv2.KMEANS_PP_CENTERS)
    return labels.reshape(feature_map.shape[:2]), centers

# rub = granica izmedu dva razlicita klastera (piksel i susjed nisu isti)
edge[:, :-1][labels[:, :-1] != labels[:, 1:]] = 255
edge[:-1, :][labels[:-1, :] != labels[1:, :]] = 255
```

Budući da se prozirne boce (staklo ili bistra plastika) bojom često stope s pozadinom pa ih klasteriranje po boji ne prepozna, uveden je pomoćni prolaz koji istu K-means podjelu

primjenjuje na kartu teksture (lokalnu varijancu). Tijelo prozirne boce, iako slabo obojeno, ima izraženu teksturu (odsjaji, nabori, navoj čepa) po kojoj se odvaja od glatke pozadine. Time druga paradigma ostaje dosljedna sebi (uvijek se koristi K-means podjela), ali postaje otpornija na težak slučaj prozirnih boca.

4.6. VARIJACIJSKA PARADIGMA (CHAN-VESE AKTIVNA KONTURA)

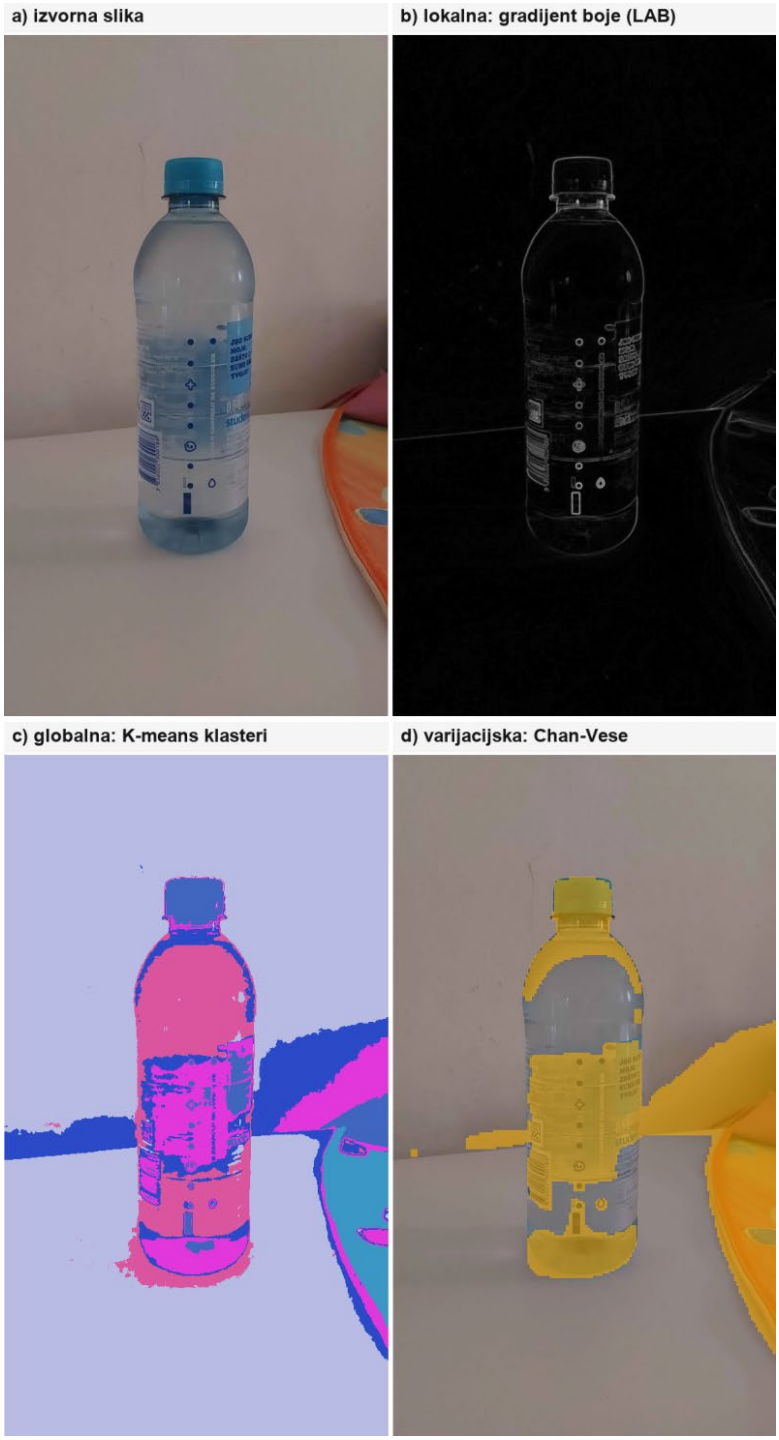
Treća paradigma euklidsku udaljenost računa između piksela i statistike (prosjeka) cijele regije. Riječ je o Chan-Vese modelu aktivne konture bez rubova [11], koji sliku dijeli na dvije regije (bocu i pozadinu) tako da svaki piksel završi u onoj regiji čijem je prosjeku boje bliži. Kontura se pomiče sve dok se ne postigne najmanji ukupni zbroj kvadratnih euklidskih odstupanja piksela od prosjeka vlastite regije, odnosno dok obje regije ne postanu što „čišće“ (unutar svake su regije boje što sličnije). Za razliku od gradijentne metode, koja gleda samo lokalne prijelaze, ova metoda gleda globalnu sličnost cijele regije, pa je otpornija na šum i slabe rubove. Srž iterativnog postupka (natjecanje regija) prikazana je u nastavku:

```
for _ in range(ITERATIONS):
    c1 = feats[inside].mean(axis=0)         # prosjecna boja UNUTAR konture
    c2 = feats[~inside].mean(axis=0)        # prosjecna boja IZVAN konture
    d1 = ((feats - c1) ** 2).sum(axis=2)    # kvadr. euklidska udalj. do c1
    d2 = ((feats - c2) ** 2).sum(axis=2)    # kvadr. euklidska udalj. do c2

    # svaki rubni piksel prelazi u regiju cijem je PROSJEKU boje blizi
    u[boundary & (d1 <  d2)] = 1            # postaje "unutar"
    u[boundary & (d1 >= d2)] = 0            # postaje "izvan"
```

U svakoj se iteraciji ponovno izračunavaju prosječne boje unutar i izvan konture (c1 i c2), a zatim se svaki rubni piksel pridružuje regiji čijem je prosjeku bliži. Postupak se ponavlja dok se kontura ne ustali. Ista se energija koristi i za procjenu razine tekućine: kontura se ograniči na obitelj vodoravnih linija unutar siluete boce, a optimalna je ona linija koja gornji (zrak) i donji (tekućina) dio ostavlja što ujednačenijima.

Slika 3 prikazuje kako izgleda rezultat svake od triju paradigmi primijenjen na istu fotografiju boce: lokalna paradigma daje kartu rubova, globalna daje obojene klastere, a varijacijska daje ispunjenu siluetu boce. Važno je napomenuti da je svaka paradigma namjerno zadržana „čistom“, odnosno da svaki algoritam u sve tri faze (lokalizacija, obris i razina) koristi isključivo vlastitu paradigmu i ne posuđuje postupke drugih. Time usporedba u sljedećim poglavljima stvarno uspoređuje tri pristupa, a ne njihovu mješavinu.



Slika 3. *Tri paradigme korištenja euklidske udaljenosti na istoj boci: lokalna (gradijent boje), globalna (K-means klasteri) i varijacijska (Chan-Vese silueta) (Izvor: obrada autora)*

5. EKSPERIMENTALNA TESTIRANJA NA RAZLIČITIM SKUPOVIMA SLIKA

Eksperimentalni dio predstavlja središnji dio ovoga rada jer se u njemu opisani algoritmi provjeravaju na stvarnim fotografijama i njihova se točnost mjeri objektivnim mjerama. Kao praktični problem odabrana je kontrola razine punjenja boca, koja je čest zadatak u sustavima industrijske vizualne inspekcije. Taj se problem izravno oslanja na detekciju rubova. Granica između zraka i tekućine, kao i granica između boce i pozadine, ključni su rubovi koje je potrebno pouzdano prepoznati. Time se problem određivanja razine punjenja može promatrati kao tipičan problem detekcije rubova i granica objekata, pa je pogodan za provjeru pristupa temeljenih na euklidskoj udaljenosti. Namjerno su korištene stvarne, nekontrolirane fotografije umjesto umjetno pripremljenih slika, kako bi se robusnost algoritama ispitala u uvjetima bliskima svakodnevnoj primjeni.

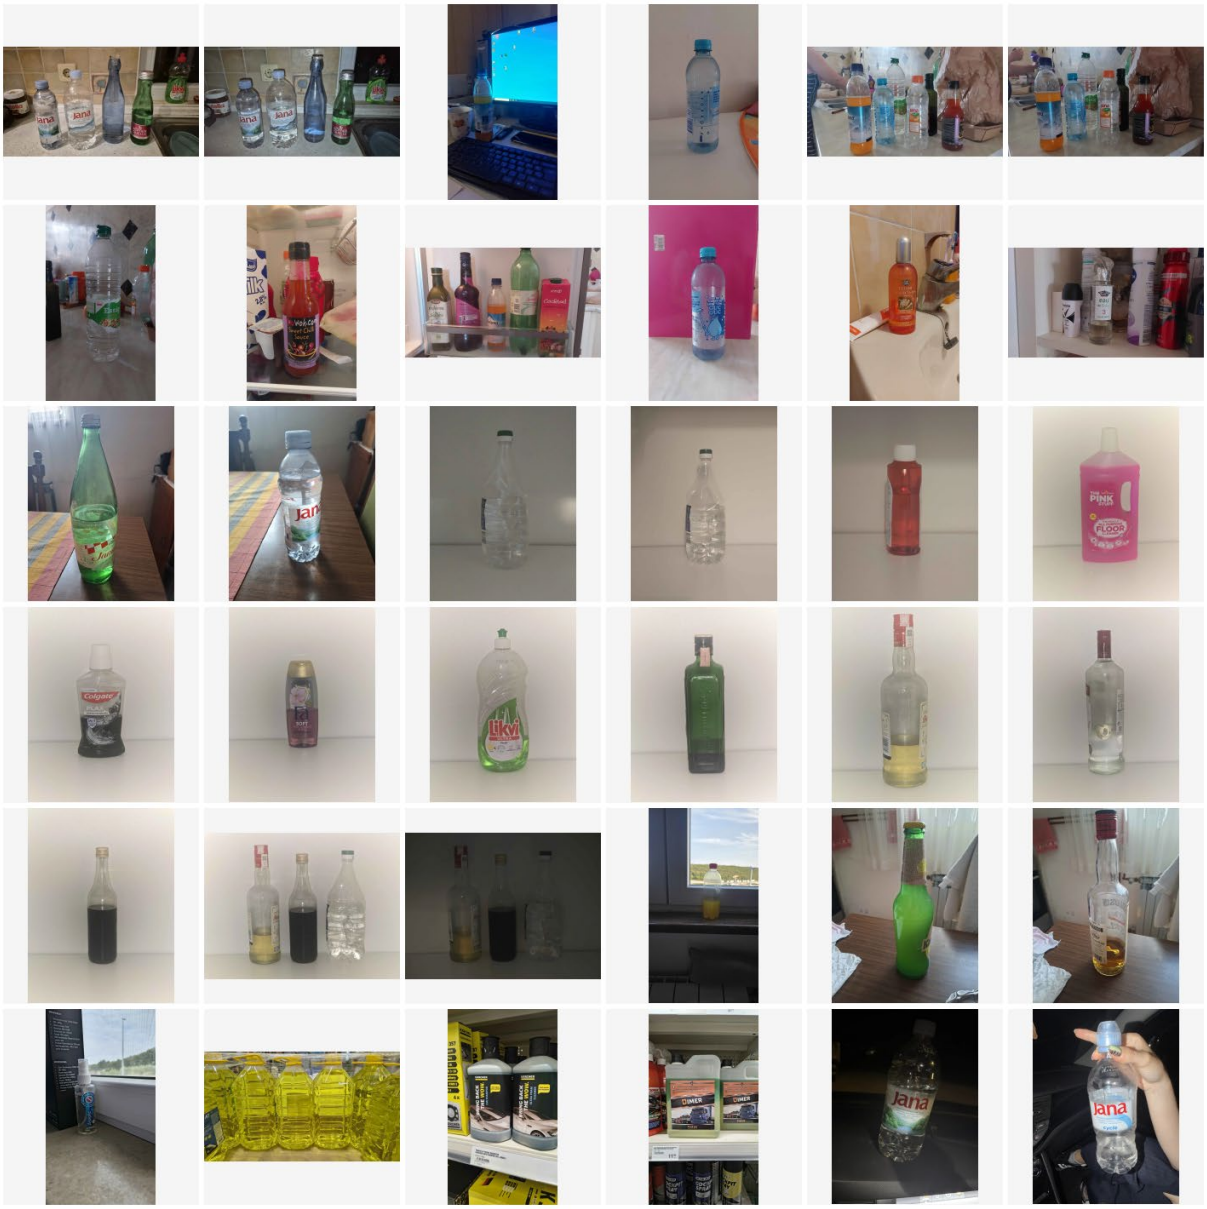
5.1. SKUP PODATAKA

Za potrebe ispitivanja izrađen je vlastiti skup podataka koji se sastoji od 36 fotografija na kojima se ukupno nalazi 65 boca. Fotografije su prikupljene iz svakodnevne uporabe i trgovina te uključuju različite vrste boca i ambalaže, kao što su plastične i staklene boce, prozirne i obojene, s vodom, sokovima, obojenim tekućinama i alkoholnim pićima. Slike su snimljene mobilnim uređajem u stvarnim, nekontroliranim uvjetima, a zatim su radi ujednačenosti obrade skalirane na širinu od 958 piksela, uz visine u rasponu od 539 do 1730 piksela ovisno o orijentaciji i obliku kadra. Raznolikost skupa podataka prikazana je na Slici 4.



Slika 4. *Raznolikost skupa podataka: različit broj boca, jačina osvjetljenja i složenost scene*

Cjelovit pregled skupa podataka, sa svih 36 fotografija zajedno, prikazan je na Slici 5. Na njemu je vidljiv širok raspon boca (voda, sokovi, ulja, sirupi, alkoholna pića i sredstva za čišćenje) te scena, od jednostavnih studijskih do zatrpanih kuhinjskih i trgovačkih kadrova.



Slika 5. *Sve fotografije skupa podataka (36 slika s ukupno 65 boca) (Izvor: obrada autora)*

Osim po uvjetima snimanja, boce se razlikuju i po vlastitim svojstvima koja izravno utječu na težinu detekcije, a primjeri pojedinih kategorija prikazani su na Slici 6. Prema materijalu razlikuju se staklene i plastične boce; prema prozirnosti prozirne boce (bistro staklo ili plastika kroz koju se vidi sadržaj) i obojene boce (primjerice tamno ili tintano staklo); a prema sadržaju boce s vodom, sokovima i drugim obojanim tekućinama. Ova su svojstva bitna jer prozirne boce s vodom predstavljaju najteži slučaj, budući da se i stijenka i sadržaj bojom stapaju s pozadinom, dok obojene tekućine, poput tamnoga soka, daju jasan kontrast pa se granica tekućine lakše prepoznaje.



Slika 6. *Primjeri kategorija boca u skupu podataka: prema vrsti boce (prozirna, obojena, staklena, plastična) i prema sadržaju (voda, sok, obojana tekućina) (Izvor: obrada autora)*

Fotografije su namjerno snimane tako da pokrivaju širok raspon uvjeta, pri čemu je svaka slika razvrstana prema četirima obilježjima, izravno zapisanima u nazivu datoteke. Prvo je obilježje broj boca na slici (jedna ili više boca u istom kadru). Drugo je jačina osvjetljenja (slabo, umjereno ili jako), čime se ispituje otpornost algoritama na promjene svjetline. Treće je razina punjenja (niska ili visoka). Četvrto je složenost scene. Jednostavne scene imaju čistu, jednoličnu pozadinu (bocu na stolu ili uza zid), dok kompleksne scene sadrže nered, više predmeta i neujednačenu pozadinu (primjerice kuhinjski pult). Uz navedeno, boce su podijeljene i prema prozirnosti (prozirne i obojene), pri čemu prozirne boce predstavljaju poseban izazov jer se njihov sadržaj bojom stapa s pozadinom. Raspodjela boca po pojedinim obilježjima prikazana je u Tablici 1.

OBILJEŽJE	KATEGORIJA	BROJ BOCA
Broj boca u kadru	jedna	26
	više	39
Jačina osvjetljenja	slabo	29
	umjereno	22
	jako	14
Razina punjenja	niska	36
	visoka	29
Složenost scene	jednostavna	22
	kompleksna	43
Prozirnost	prozirna	18
	obojena	47

Tablica 1. *Raspodjela boca u skupu podataka po obilježjima (ukupno 65 boca) (Izvor: obrada autora)*

Ovakav skup podataka omogućuje ne samo mjerenje ukupne točnosti, nego i analizu ponašanja algoritama u pojedinim uvjetima, primjerice pri slabom osvjetljenju ili u složenim scenama, što je detaljno prikazano u sljedećem poglavlju.

5.2. REFERENTNE VRIJEDNOSTI (GROUND TRUTH)

Kako bi se točnost algoritama uopće mogla izmjeriti, za svaku je bocu potrebno unaprijed poznavati točan odgovor. Zbog toga su sve boce ručno označene posebnom pomoćnom skriptom. Za svaku je bocu ručno postavljen okvir (pravokutnik oko boce) te vodoravna crta na stvarnoj površini tekućine, kao što je prikazano na Slici 7. Iz tih se podataka izračunava stvarni postotak punjenja prema istoj formuli kojom ga računaju i algoritmi, odnosno kao omjer visine ispunjenog dijela i ukupne visine boce:

$$\text{postotak punjenja} = 100 \times (\text{donji rub boce} - \text{visina površine tekućine}) / \text{visina boce}$$



Slika 7. *Primjer ručno označenih referentnih vrijednosti: okvir boce i stvarna razina tekućine (Izvor: obrada autora)*

Time se dobiva pošteni temelj za usporedbu: svaka procjena algoritma uspoređuje se s ljudski određenom istinom, i za položaj boce i za razinu tekućine.

5.3. MJERE USPOREDBE

Točnost algoritama mjeri se u dvjema odvojenim skupinama mjera, budući da algoritam mora uspješno obaviti dva zadatka, a to su pronaći bocu i procijeniti razinu. Prva skupina mjeri uspješnost lokalizacije boce. Podudarnost algoritamskog i stvarnog okvira izražava se mjerom preklapanja (Intersection over Union, IoU), koja predstavlja omjer površine presjeka i površine unije dvaju okvira; vrijednost 1 znači savršeno preklapanje, a 0 nikakvo. Sam izračun mjere preklapanja prikazan je u nastavku:

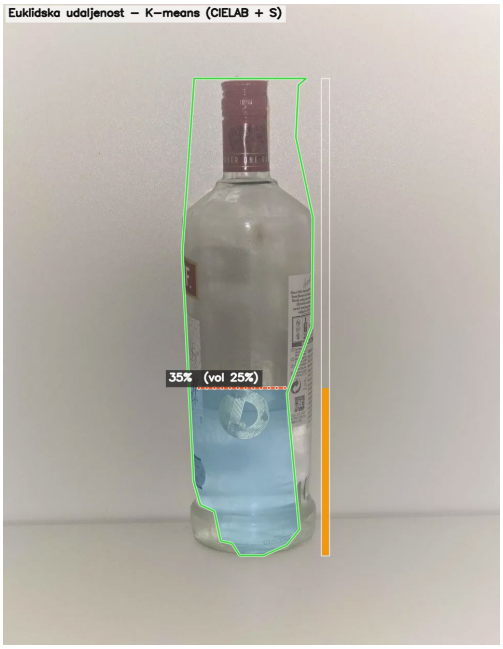
```
def iou(box_a, box_b):
    ax, ay, aw, ah = box_a
    bx, by, bw, bh = box_b
    # presjek dvaju okvira
    ix1, iy1 = max(ax, bx), max(ay, by)
    ix2, iy2 = min(ax + aw, bx + bw), min(ay + ah, by + bh)
    presjek = max(0, ix2 - ix1) * max(0, iy2 - iy1)
    unija = aw * ah + bw * bh - presjek
    return presjek / unija if unija else 0.0   # 1 = savrseno, 0 = nema preklapanja
```

Boca se smatra uspješno pronađenom ako je IoU najmanje 0,4. Na temelju toga broje se ispravne detekcije (TP), promašene boce (FN) i lažne detekcije (FP), iz čega se izračunavaju preciznost (udio ispravnih među svim detekcijama) i odziv (udio pronađenih među svim stvarnim bocama).

Druga skupina mjeri točnost procijenjene razine tekućine, i to samo za uspješno pronađene boce. Koristi se srednja apsolutna pogreška (MAE), koja pokazuje za koliko postotnih bodova procjena u prosjeku odstupa od stvarne razine (postotni bod je apsolutna razlika u postotku ispunjenosti, pa primjerice procjena od 60 % naspram stvarnih 50 % daje pogrešku od 10 postotnih bodova), te korijen srednje kvadratne pogreške (RMSE), koji jače kažnjava velike promašaje. Prati se i najveća pojedinačna pogreška te prosječno vrijeme obrade po slici. Jednostavno rečeno, IoU govori koliko je dobro pogođeno gdje je boca, a MAE i RMSE koliko je dobro pogođeno koliko je puna.

5.4. PRIMJER OUTPUTA ALGORITMA

Rezultat obrade svake se boce iscrtava izravno na sliku radi lakšeg pregleda i provjere. Zelenom je bojom označen obris pronađene boce, vodoravnom crtom s postotkom označena je procijenjena razina tekućine, a s desne strane boce nalazi se pokazivač ispunjenosti na kojem narančasti dio odgovara procijenjenom udjelu tekućine (Slika 8). Uz postotak razine prikazuje se i volumetrijski korigirani postotak koji uzima u obzir zaobljeni oblik boce. Ta je razlika bitna jer uski vrat i rame boce sadrže manje tekućine od jednako visokog dijela trupa, pa ista visina razine ne znači uvijek i isti udio volumena; korekcija se računa iz širine obrisa boce po visini. Ovakav vizualni prikaz omogućuje da se na prvi pogled uoči je li boca ispravno pronađena i je li razina razumno procijenjena.



Slika 8. *Primjer anotiranog rezultata: obris boce (zeleno), procijenjena razina tekućine i pokazivač ispunjenosti (Izvor: obrada autora)*

6. USPOREĐIVANJE REZULTATA

Uspoređuju se tri paradigme, i to lokalna (gradijent boje u CIELAB-u), globalna (K-means) i varijacijska (Chan-Vese), te ablacijska RGB varijanta gradijentne metode. Cilj je utvrditi koji pristup daje najbolje rezultate i u kojim uvjetima, kako pri pronalaženju boce, tako i pri procjeni razine tekućine.

6.1. UKUPNI REZULTATI

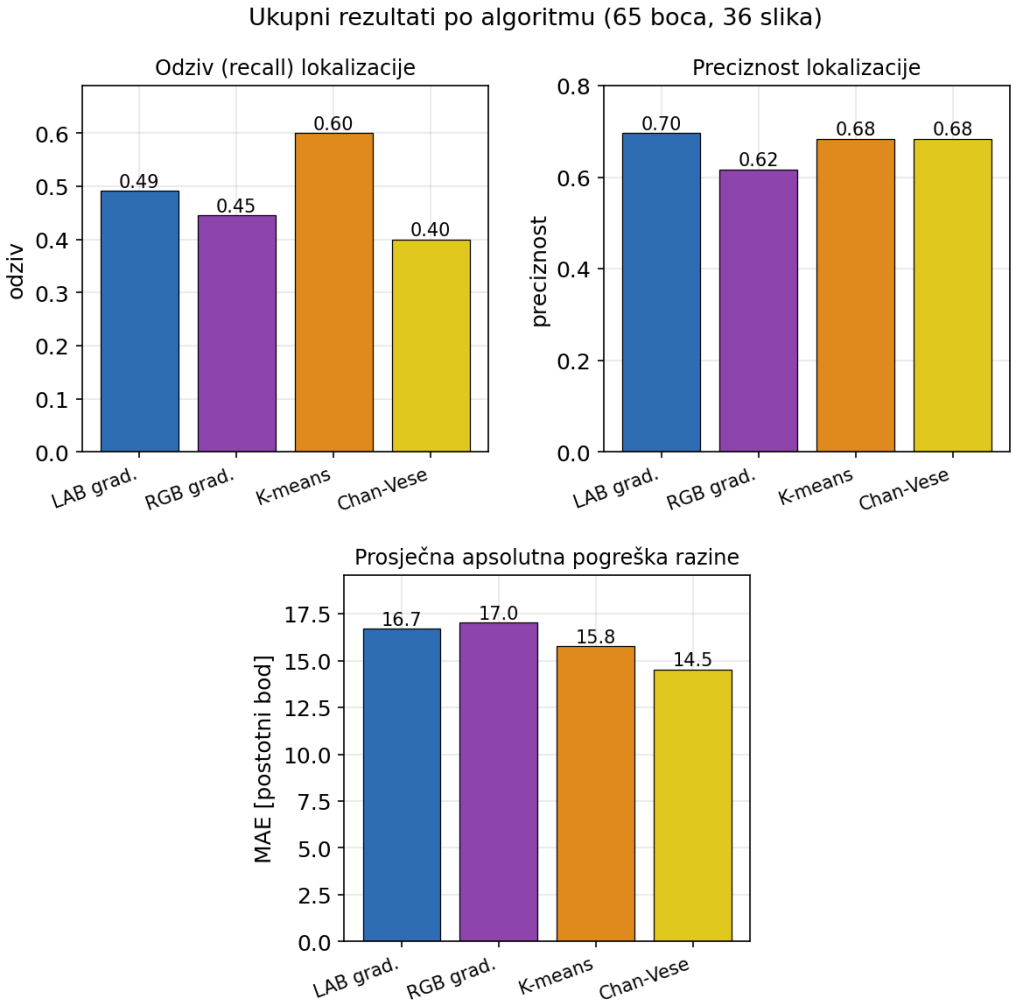
Tablica 2 prikazuje ukupne rezultate svih četiriju izvedbi na 65 boca. Prije tumačenja vrijednosti korisno je pojasniti mjerne jedinice u zaglavlju tablice. Preciznost, odziv i prosječni IoU mjere su u rasponu od 0 do 1, pri čemu vrijednost bliža jedinici znači bolji rezultat, a nula najlošiji, pa se primjerice odziv od 0,60 čita kao da je pronađeno 60 posto stvarnih boca. Srednja apsolutna pogreška (MAE), korijen srednje kvadratne pogreške (RMSE) i najveća pogreška izraženi su u postotnim bodovima (p.b.), odnosno u apsolutnoj razlici između procijenjenoga i stvarnog postotka ispunjenosti boce, tako da pogreška od 15 postotnih bodova znači da procjena u prosjeku odstupa petnaest posto punjenja od stvarne razine. Vrijeme obrade po slici izraženo je u sekundama. Ukratko, kod prvih triju mjera veća je vrijednost bolja, dok je kod pogrešaka i vremena bolja manja vrijednost. Već se iz tablice vidi da nijedna metoda nije istodobno najbolja u lokalizaciji i u točnosti razine, što upućuje na različite kompromise među paradigmama.

ALGORITAM	PRECIZNOST [0–1]	ODZIV [0–1]	IOU [0–1]	MAE [P.B.]	RMSE [P.B.]	MAKS. [P.B.]	VRIJEME [S]
LAB gradijent (lokalna)	0,70	0,49	0,75	16,7	22,7	59,2	0,26
RGB gradijent (ablacija)	0,62	0,45	0,77	17,0	23,7	56,4	0,25
K-means (globalna)	0,68	0,60	0,77	15,8	21,3	53,0	2,20
Chan-Vese (varijacijska)	0,68	0,40	0,74	14,5	19,3	44,9	1,04

Tablica 2. *Ukupni rezultati po algoritmu (65 boca, 36 slika) (Izvor: obrada autora)*

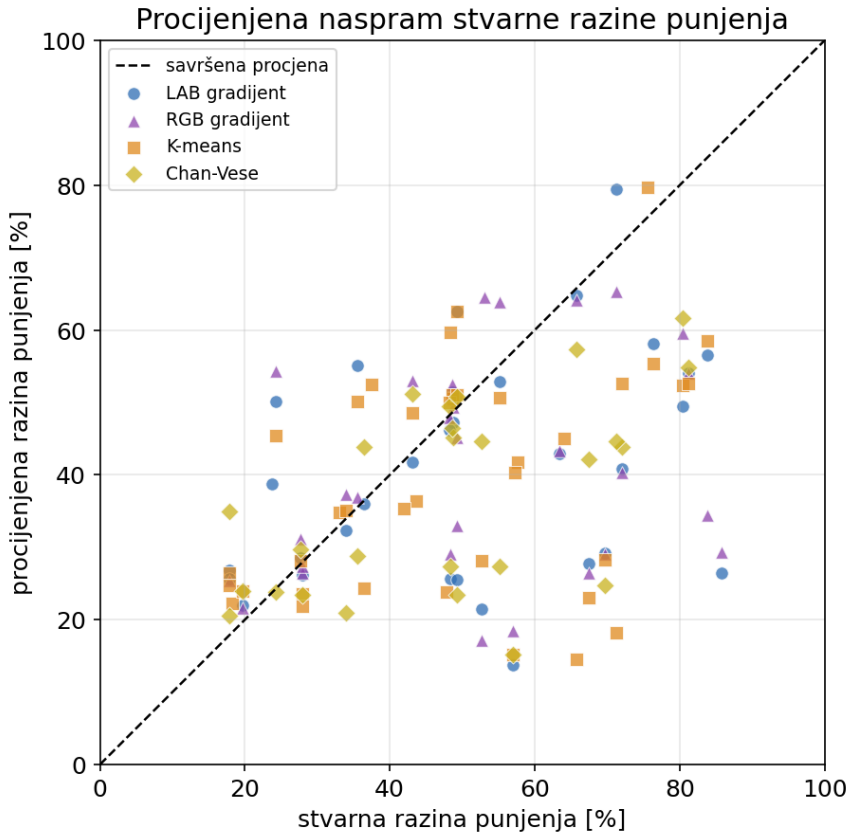
Iz rezultata proizlazi nekoliko zaključaka. Najbolji odziv lokalizacije postiže K-means (0,60), što znači da pronalazi najveći udio stvarnih boca; to je i očekivano jer njegov pomoćni prolaz po teksturi hvata i prozirne boce koje ostale metode često previde. S druge strane, Chan-Vese ima najniži odziv (0,40) jer je najkonzervativniji pa najviše boca previdi, ali zato daje najtočniju procjenu razine, odnosno najmanji MAE (14,5 postotnih bodova), najmanji RMSE i, što je posebno važno, najmanju najveću pogrešku (44,9 naspram 53 do 59 kod ostalih). To znači da Chan-Vese ne samo da u prosjeku griješi manje, nego i u najgorem slučaju promaši najmanje.

Usporedba gradijentne metode u dvama prostorima boja potvrđuje pretpostavku iz trećega poglavlja, odnosno CIELAB varijanta (LAB gradijent) nadmašuje RGB varijantu i po odzivu (0,49 naspram 0,45) i po preciznosti (0,70 naspram 0,62) i po pogrešci razine. To pokazuje da perceptivno ujednačen prostor boja doista pridonosi robusnosti detekcije, čime ablacija opravdava izbor CIELAB-a kao osnovnog prostora. Gradijentne su metode ujedno najbrže (oko 0,25 sekunde po slici), dok je K-means najsporiji (2,2 sekunde) zbog ponovljenog klasteriranja. Isti su rezultati grafički prikazani na Slici 9.



Slika 9. *Ukupni rezultati po algoritmu: odziv, preciznost i srednja apsolutna pogreška razine (Izvor: obrada autora)*

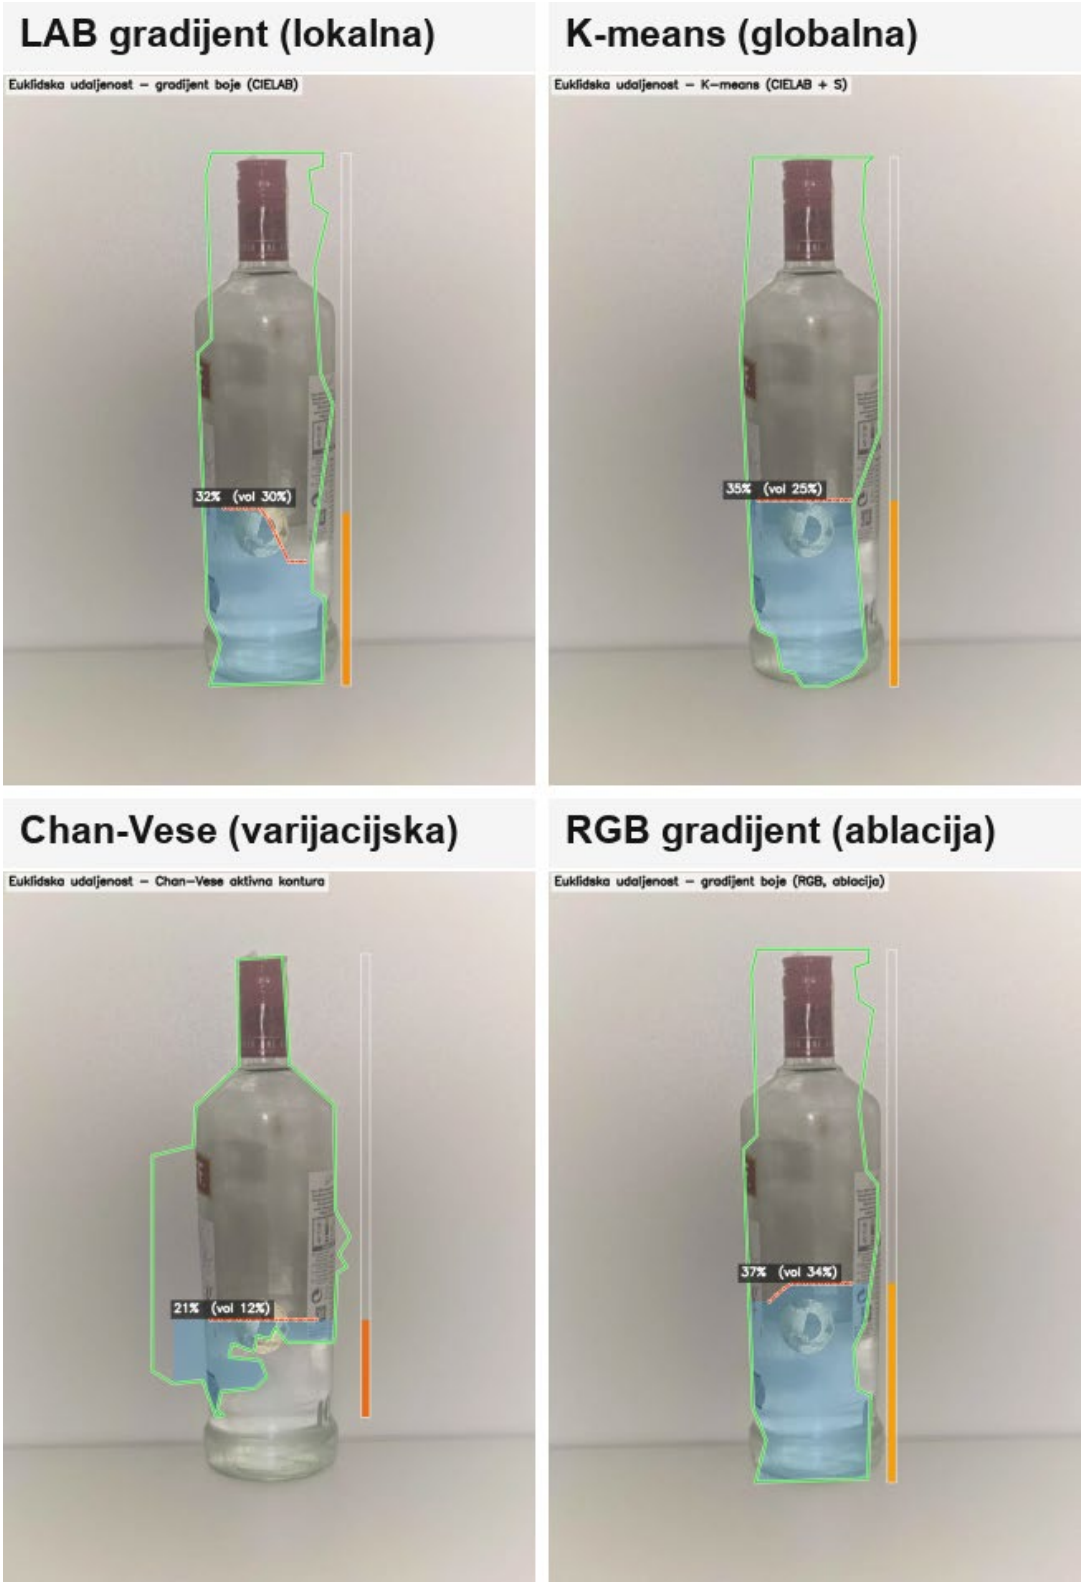
Odnos procijenjene i stvarne razine za sve uspješno pronađene boce prikazan je na Slici 10. Točke se grupiraju oko dijagonale savršene procjene, što potvrđuje da procjene dobro prate stvarnu razinu, no uočljivo je i blago podcjenjivanje pri visokim razinama punjenja, kada je granica tekućine blizu ramena boce i teže uočljiva. Rasap točaka odgovara izmjerenoj srednjoj pogrešci od oko 15 postotnih bodova.



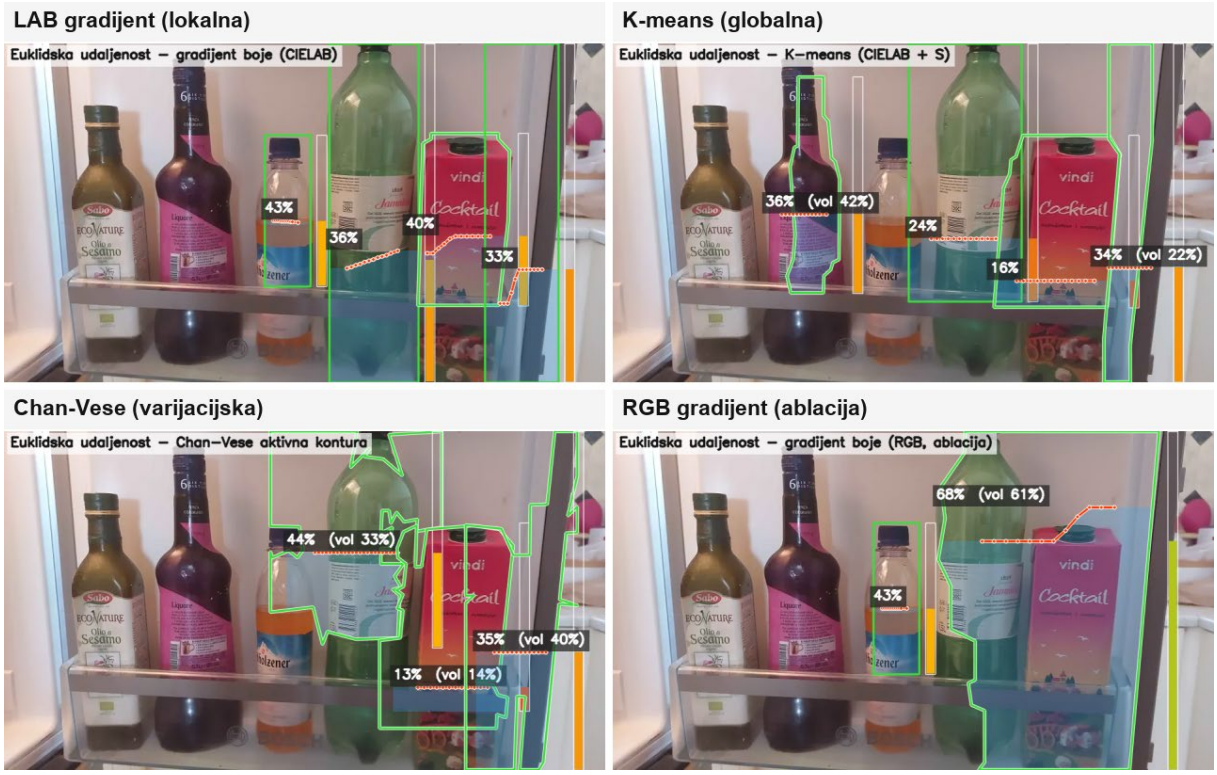
Slika 10. *Procijenjena naspram stvarne razine punjenja za sve uspješno pronađene boce (Izvor: obrada autora)*

6.2. VIZUALNA USPOREDBA NA POJEDINAČNIM SCENAMA

Slika 11 prikazuje rezultate svih četiriju algoritama na istoj jednostavnoj sceni s jednom bocom. U takvim su uvjetima sve metode pronašle bocu i procijenile razinu blisku stvarnoj, uz manja međusobna odstupanja. Nasuprot tome, Slika 12 prikazuje kompleksnu scenu s više boca i neujednačenom pozadinom, gdje dolazi do izraženijih razlika, pa se neke boce ne pronađu, a procjene razine su nesigurnije. Ova dva primjera dobro ilustriraju glavni nalaz. U kontroliranim uvjetima metode rade pouzdano, dok im točnost pada u nekontroliranim, zatrpanim scenama.



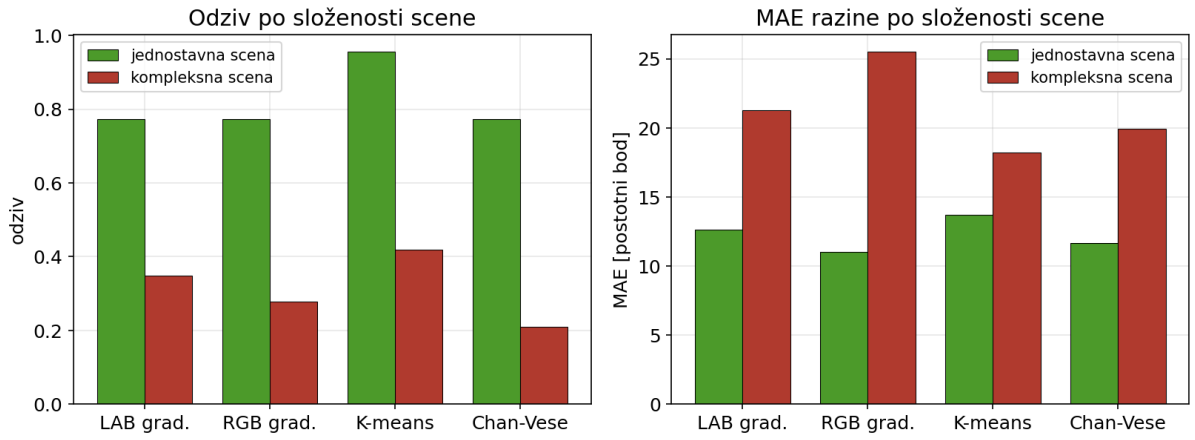
Slika 11. *Usporedba četiriju algoritama na jednostavnoj sceni (jedna boca, jako osvjetljenje) (Izvor: obrada autora)*



Slika 12. *Usporedba četiriju algoritama na kompleksnoj sceni (više boca, umjereno osvjetljenje) (Izvor: obrada autora)*

6.3.UTJECAJ SLOŽENOSTI SCENE

Složenost scene pokazala se najutjecajnijim čimbenikom. Slika 13 i Tablica 3 pokazuju da na jednostavnim scenama svi algoritmi postižu visok odziv (do 0,96 kod K-meansa) i nisku pogrešku razine (11 do 14 postotnih bodova), dok na kompleksnim scenama odziv pada na 0,21 do 0,42, a pogreška raste na 18 do 25 postotnih bodova. Razlog je jasan jer u zatrpanoj sceni drugi predmeti stvaraju lažne rubove i klastere slične boci, pa lokalizacija postaje znatno teža. K-means i ovdje zadržava najbolji odziv, dok gradijentne metode i Chan-Vese na jednostavnim scenama daju nešto točniju razinu.



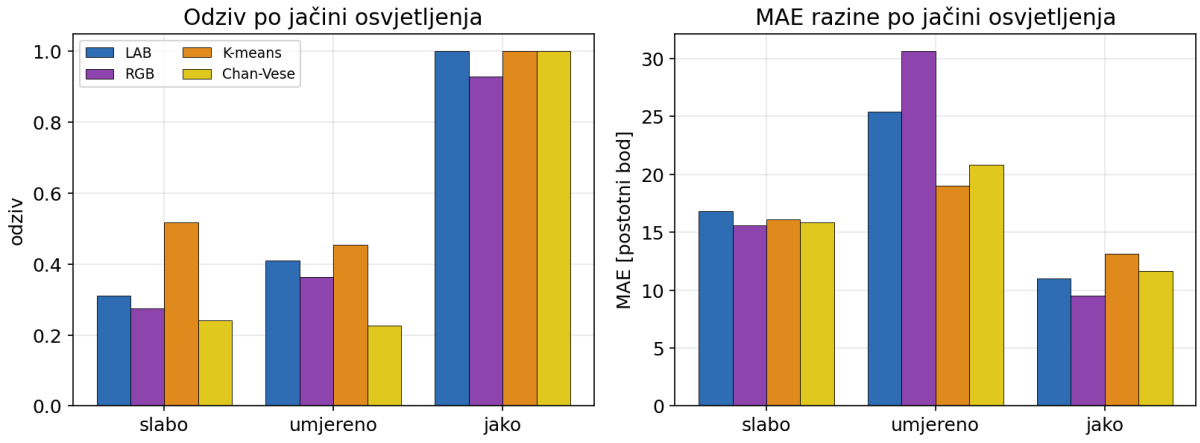
Slika 13. *Odziv i srednja apsolutna pogreška razine po složenosti scene (Izvor: obrada autora)*

ALGORITAM	ODZIV, JEDNOST. [0–1]	MAE, JEDNOST. [P.B.]	ODZIV, KOMPL. [0–1]	MAE, KOMPL. [P.B.]
LAB gradijent	0,77	12,6	0,35	21,3
RGB gradijent	0,77	11,1	0,28	25,5
K-means	0,96	13,7	0,42	18,2
Chan-Vese	0,77	11,7	0,21	19,9

Tablica 3. *Rezultati po složenosti scene (MAE u postotnim bodovima) (Izvor: obrada autora)*

6.4. UTJECAJ OSVJETLJENJA

Jačina osvjetljenja također znatno utječe na rezultate (Slika 14). Pri jakom osvjetljenju svi algoritmi postižu gotovo savršen odziv (blizu 1,0) i najnižu pogrešku razine (od 9,5 do 13 postotnih bodova), što znači da u dobro osvijetljenim, jasnim uvjetima sustav radi pouzdano. Pri slabom osvjetljenju odziv opada, no K-means se i ovdje najbolje snalazi (0,52). Zanimljivo je da umjereno osvjetljenje ne daje najbolje, nego često najlošije rezultate za razinu; razlog nije sama svjetlina, nego činjenica da su mnoge slike snimljene pri umjerenom osvjetljenju ujedno bile i kompleksne scene s visokim, djelomično prozirnim bocama, pa se učinci tih čimbenika preklapaju. Ovaj primjer pokazuje da pojedinačne mjere treba tumačiti u kontekstu cijeloga skupa.



Slika 14. *Odziv i srednja apsolutna pogreška razine po jačini osvjetljenja (Izvor: obrada autora)*

6.5. UTJECAJ PROZIRNOSTI BOCE

Prozirnost boce poseban je izazov jer se bistar sadržaj bojom stapa s pozadinom. Na jednostavnim scenama K-means zahvaljujući pomoćnom prolazu po teksturi pronalazi sve prozirne boce (odziv 1,0), dok Chan-Vese na njima postiže najtočniju razinu (MAE 9,5 postotnih bodova). Na obojenim bocama u jednostavnim scenama gradijentne metode daju nešto točniju razinu jer je granica tekućine izraženija. U složenim scenama razlike se smanjuju jer svim metodama pada uspješnost. Ovi rezultati potvrđuju da su tri paradigme komplementarne, svaka je najjača u drugačijim uvjetima.

6.6. ODABIRANJE ALGORITMA ZA NAJBOLJE REZULTATE

Na temelju svih usporedbi ne postoji jedan pobjednik u svim uvjetima, nego se paradigme pokazuju komplementarnima. K-means je najbolji izbor za lokalizaciju, osobito kada su prisutne prozirne boce, slabo osvjetljenje ili složenije scene, po cijenu najduljeg vremena obrade. Chan-Vese daje najtočniju i najstabilniju procjenu razine tekućine te najmanju najveću pogrešku, pa je najprikladniji kada je važna preciznost očitanja. LAB gradijentna metoda najbrža je i vrlo dobra na jednostavnim, dobro osvijetljenim scenama s obojenim bocama, dok RGB varijanta služi kao referenca koja potvrđuje prednost CIELAB prostora. U praksi bi se najbolji rezultat postigao spajanjem jakih strana pojedinih paradigmi, primjerice lokalizacijom K-meansom i procjenom razine u stilu Chan-Vesea.

Komplementarnost paradigmi potvrđena je i jednostavnim spajanjem njihovih rezultata. Kada se za svaku bocu uzme medijan procjena svih četiriju algoritama, dobiva se srednja apsolutna pogreška od 14,2 postotna boda, što je nešto bolje od svakoga pojedinog algoritma. Još je važnije da takvo spajanje pokriva 44 boce, više nego ijedan algoritam zasebno (najviše 39), jer je dovoljno da bocu pronađe barem jedan od njih. Vidi se da paradigme ne samo da imaju različite jake strane, nego se te strane mogu i objediniti u pouzdaniji sustav.

7. PREDNOSTI I NEDOSTATCI ODABRANIH ALGORITAMA

Na temelju provedenih ispitivanja u ovom se poglavlju sažimaju prednosti i nedostaci pojedinih algoritama. Iako se svi temelje na istoj mjeri, euklidskoj udaljenosti, način na koji je primjenjuju daje im različita svojstva, pa svaki ima svoje jače i slabije strane.

7.1. LOKALNA PARADIGMA (GRADIJENT BOJE)

Glavna je prednost gradijentne metode jednostavnost i brzina; obrada jedne slike traje oko 0,25 sekunde, što je najbrže od svih pristupa. Metoda je vrlo dobra na jednostavnim, dobro osvijetljenim scenama i osobito na obojenim bocama, gdje je granica tekućine izražena. Zahvaljujući računanju u CIELAB prostoru robusna je na umjerene promjene osvjetljenja. Glavni su nedostaci slabija uspješnost na prozirnim bocama, čiji su rubovi isprekidani, te osjetljivost na složene scene, u kojima drugi predmeti stvaraju mnoštvo lažnih rubova. Uz to, gradijent ponekad razlomi obris boce na više dijelova.

7.2. GLOBALNA PARADIGMA (K-MEANS)

K-means se pokazao najuspješnijim u pronalaženju boca, s najvećim odzivom (0,60) i najboljom otpornošću na prozirne boce, slabo osvjetljenje i složenije scene. Razlog je u tome što grupira cijele regije slične boje umjesto da traži pojedinačne rubove, a pomoćni prolaz po teksturi hvata i prozirne boce. Glavni je nedostatak brzina, jer uz ponovljeno klasteriranje obrada traje oko 2,2 sekunde po slici, što je najsporije od svih metoda. Uz to, procjena razine nešto je manje precizna nego kod Chan-Vesea, a metoda proizvodi i nešto više lažnih detekcija.

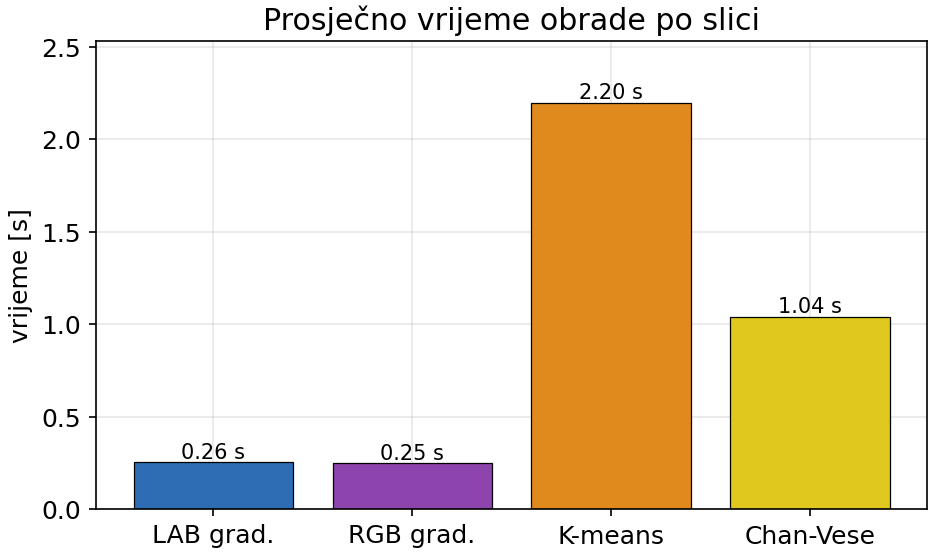
7.3. VARIJACIJSKA PARADIGMA (CHAN-VESE)

Chan-Vese daje najtočniju procjenu razine tekućine (najmanji MAE i RMSE) te, što je osobito važno za praktičnu primjenu, najmanju najveću pogrešku, odnosno u najgorem slučaju promaši znatno manje od ostalih metoda. Silueta dobivena minimizacijom energije stabilna je i čista, a metoda ne stvara suvišne fragmente. Glavni je nedostatak najniži odziv od 0,40, jer je metoda konzervativna i sklona previdjeti prozirne boce na jednoličnoj pozadini od koje se teško odvaja. Brzina je umjerena (oko 1 sekunde po slici). Prosječna vremena obrade svih algoritama uspoređena su na Slici 15.

7.4. RGB GRADIJENT (ABLACIJA)

RGB varijanta gradijentne metode nije zamišljena kao samostalno rješenje, nego kao ablacijska usporedba, odnosno kontrolni pokus kojim se provjerava koliko na rezultat utječe sam odabir prostora boja. Riječ je o posve istom postupku kao kod lokalne paradigme, s jedinom razlikom

da se euklidska udaljenost boje susjednih piksela računa u RGB prostoru umjesto u CIELAB prostoru. Njezina je jedina praktična prednost brzina, jednaka onoj CIELAB varijante (oko 0,25 sekunde po slici), uz istu jednostavnost izvedbe. Glavni je nedostatak što RGB prostor nije perceptivno ujednačen, pa jednaka brojčana razlika između boja ne odgovara jednakoj razlici koju opaža ljudsko oko, zbog čega je metoda osjetljivija na promjene osvjetljenja. To se izravno vidi u rezultatima, jer RGB varijanta zaostaje za CIELAB varijantom po svim mjerama, i po odzivu (0,45 naspram 0,49) i po preciznosti (0,62 naspram 0,70) i po pogrešci razine (17,0 naspram 16,7 postotnih bodova). Time RGB varijanta potvrđuje da je izbor CIELAB prostora opravdan, a njezina je vrijednost u radu prije svega referentna, kao mjerilo prema kojem se vidi stvaran doprinos perceptivno ujednačenoga prostora boja.



Slika 15. *Prosječno vrijeme obrade po slici za pojedini algoritam (Izvor: obrada autora)*

7.5. ZAJEDNIČKI OSVRT

Zajednička prednost svih triju pristupa jest u tome što se temelje na jednoj jednostavnoj, intuitivnoj i računalno nezahtjevnoj mjeri, ne zahtijevaju učenje na velikim skupovima podataka niti posebno računalno sklopovlje te su lako razumljivi i podesivi. Time se pokazuje da euklidska udaljenost može poslužiti kao objedinjujuća okosnica za tri različite obitelji metoda detekcije rubova i segmentacije. Zajednička su ograničenja slabija uspješnost na prozirnim bocama, u zatrpanim scenama i pri nepovoljnom osvjetljenju, kao i u rubnim slučajevima kada je stvarna razina posve pri vrhu ili dnu boce, izvan raspona pretrage. Upravo zato paradigme najbolje djeluju kao komplementaran skup, a ne kao pojedinačne, izolirane metode. U praktičnoj primjeni izbor paradigme stoga ovisi o tome je li prioritet pronaći što više boca, postići što točniju razinu ili obraditi sliku što brže.

8. MOGUĆNOST PRIMJENE U INDUSTRIJSKIM SUSTAVIMA

Rezultati ovoga eksperimenta imaju izravnu praktičnu vrijednost jer se odabrani problem, kontrola razine punjenja boca, svakodnevno pojavljuje u industriji. Sustavi za automatsku kontrolu razine punjenja koriste se pri punjenju vode, sokova, alkoholnih pića, farmaceutskih proizvoda i različitih kemikalija, gdje je potrebno pouzdano prepoznati i odbaciti nedovoljno ili previše napunjene boce. Sustavi računalnog vida temeljeni na detekciji rubova i granica objekata stoga su važan dio suvremene industrijske vizualne inspekcije [19]. Važna prednost ovakvih klasičnih pristupa računalnog vida, u odnosu na moderne metode dubokog učenja [15], [16], [17], jest u tome što ne zahtijevaju velike označene skupove podataka za treniranje, razumljivi su i objašnjivi, a mogu se izvoditi na skromnom sklopovlju u stvarnom vremenu. Zbog toga su osobito pogodni za manje proizvođače te za sustave u kojima je važna jednostavnost održavanja i baždarenja.

Rezultati pokazuju i pod kojim bi uvjetima takav sustav bio praktično upotrebljiv. U industrijskim se linijama uvjeti obično strogo kontroliraju, pa je kamera nepomična, pozadina jednolična, a osvjetljenje stalno i često pozadinsko. Upravo u takvim uvjetima, koji odgovaraju kategoriji jednostavne scene uz jako osvjetljenje, ispitani su algoritmi postigli gotovo savršen odziv (blizu 1,0) i nisku pogrešku razine (od 9 do 13 postotnih bodova). Drugim riječima, slabiji rezultati na kompleksnim, nekontroliranim scenama posljedica su otežanih uvjeta snimanja koje industrijska okolina redovito uklanja. Slični su rezultati potvrđeni i u novijoj literaturi: suvremeni sustavi strojnog vida za inspekciju napunjenih boca postižu prosječnu točnost od oko 95 posto u kontroliranim uvjetima [18], čime se detekcija razine punjenja svrstava među zrele i pouzdane primjene računalnog vida.

Osim same razine punjenja, opisane se paradigme mogu proširiti i na druge zadatke industrijske inspekcije koji se svode na prepoznavanje rubova i regija: provjeru prisutnosti i položaja čepa i etikete, otkrivanje stranih tijela ili nečistoća u tekućini, razvrstavanje proizvoda te izdvajanje područja barkoda. Time euklidska udaljenost, kao temeljna mjera, pronalazi širu primjenu u sustavima vizualne kontrole kvalitete. Potrebno je, međutim, imati na umu i ograničenja: bez kontroliranih uvjeta snimanja, u zatrpanim i promjenjivim scenama, točnost opada, pa je za pouzdan industrijski sustav nužno osigurati ujednačenu pozadinu, stabilno osvjetljenje i nepomičnu kameru. Budući da cijeli postupak radi na jednoj fotografiji i ne zahtijeva posebno sklopovlje, moguće ga je izvoditi izravno na skromnom industrijskom računalu uz kameru postavljenu na proizvodnu liniju.

9. ZAKLJUČAK

U ovom je radu istražena primjena euklidske udaljenosti u algoritmima za detekciju rubova i granica objekata, s naglaskom na sustave industrijske vizualne inspekcije. Nakon teorijskog pregleda klasičnih metoda detekcije rubova (Robertsove, Sobelove, Prewittove i Cannyjeve metode te metoda transformacije udaljenosti) matematički je objašnjena euklidska udaljenost i njezina uloga u obradi slike. Na toj su osnovi u programskom jeziku Python implementirane tri paradigme njezine primjene: lokalna (gradijent boje), globalna (K-means) i varijacijska (Chan-Vese), uz ablacijsku RGB varijantu. Sustav je ispitan na vlastitom skupu od 36 fotografija s 65 boca, a njegova je uspješnost mjerena mjerama lokalizacije (preciznost, odziv, IoU) i točnosti razine (MAE, RMSE, najveća pogreška).

Temeljna hipoteza rada bila je da primjena euklidske udaljenosti kao osnovne mjere može omogućiti pouzdanu detekciju rubova i granica objekata te povećati robusnost u zahtjevnim uvjetima. Provedena ispitivanja tu hipotezu potvrđuju u kontroliranim uvjetima, a djelomično u nekontroliranima. U povoljnim uvjetima (jednostavna scena, jako osvjetljenje) sve tri paradigme postižu gotovo savršen odziv i nisku pogrešku razine (od 9 do 13 postotnih bodova), što odgovara točnosti primjenjivoj u praksi. Robusnost na promjene boje i osvjetljenja potvrđena je i ablacijom, koja pokazuje prednost CIELAB prostora nad RGB-om. S druge strane, u složenim, zatrpanim scenama i pri nepovoljnom osvjetljenju točnost opada, pa se hipoteza u tim uvjetima potvrđuje samo djelomično. Također se pokazalo da nijedna paradigma nije najbolja u svim uvjetima: K-means je najuspješniji u pronalaženju boca (odziv 0,60), a Chan-Vese daje najtočniju razinu (MAE 14,5 postotnih bodova) uz najmanju najveću pogrešku.

Glavni je doprinos rada pokazati da jedna jednostavna i intuitivna mjera može objediniti tri različite obitelji metoda te da su te paradigme međusobno komplementarne jer je svaka najjača u drugačijim uvjetima. Time se dobiva pregledan i objašnjiv okvir za detekciju razine punjenja, prikladan za primjenu u industrijskoj inspekciji, osobito ondje gdje su uvjeti snimanja kontrolirani.

Daljnja bi se istraživanja mogla usmjeriti u nekoliko smjerova. Prvo, jake strane pojedinih paradigmi mogle bi se spojiti u objedinjeni sustav (primjerice lokalizacija K-meansom i procjena razine u stilu Chan-Vesea). Također, poseban bi se rad mogao posvetiti pouzdanijoj obradi prozirnih boca i zatrpanih scena. Naposljetku, rezultate klasičnih pristupa temeljenih na euklidskoj udaljenosti vrijedno bi bilo usporediti s modernim metodama dubokog učenja za detekciju rubova, kako bi se jasno utvrdio odnos jednostavnosti, objašnjivosti i točnosti. Time rad pokazuje da i konceptualno jednostavne, klasične metode računalnog vida mogu ostati konkurentne u jasno definiranim i kontroliranim zadacima industrijske inspekcije.

10. LITERATURA

1. Gonzalez, R. C., Woods, R. E. (2018). Digital Image Processing (4th ed.). Pearson.

2. Canny, J. (1986). A Computational Approach to Edge Detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 8(6), 679–698.

3. Roberts, L. G. (1963). Machine Perception of Three-Dimensional Solids. Doktorska disertacija, Massachusetts Institute of Technology.

4. Prewitt, J. M. S. (1970). Object Enhancement and Extraction. U: Picture Processing and Psychopictorics. Academic Press.

5. Sobel, I., Feldman, G. (1968). A 3×3 Isotropic Gradient Operator for Image Processing. Stanford Artificial Intelligence Project (SAIL).

6. Marr, D., Hildreth, E. (1980). Theory of Edge Detection. Proceedings of the Royal Society of London. Series B, 207(1167), 187–217.

7. Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66.

8. Di Zenzo, S. (1986). A Note on the Gradient of a Multi-Image. Computer Vision, Graphics, and Image Processing, 33(1), 116–125.

9. MacQueen, J. (1967). Some Methods for Classification and Analysis of Multivariate Observations. Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability, 281–297.

10. Lloyd, S. P. (1982). Least Squares Quantization in PCM. IEEE Transactions on Information Theory, 28(2), 129–137.

11. Chan, T. F., Vese, L. A. (2001). Active Contours Without Edges. IEEE Transactions on Image Processing, 10(2), 266–277. doi:10.1109/83.902291.

12. Felzenszwalb, P. F., Huttenlocher, D. P. (2012). Distance Transforms of Sampled Functions. Theory of Computing, 8(1), 415–428.

13. Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools.

14. Harris, C. R. i dr. (2020). Array Programming with NumPy. Nature, 585, 357–362.

15. Xie, S., Tu, Z. (2015). Holistically-Nested Edge Detection. IEEE International Conference on Computer Vision (ICCV), 1395–1403.

16. Soria, X., Riba, E., Sappa, A. (2020). Dense Extreme Inception Network: Towards a Robust CNN Model for Edge Detection (DexiNed). IEEE Winter Conference on Applications of Computer Vision (WACV), 1912–1921.

17. Minaee, S., Boykov, Y., Porikli, F., Plaza, A., Kehtarnavaz, N., Terzopoulos, D. (2022). Image Segmentation Using Deep Learning: A Survey. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(7), 3523–3542.

18. Machine Vision for Detecting Defects in Liquid Bottles: An Industrial Application for the Food and Packaging Sector (2024). Cloud Computing and Data Science, 5(2). doi:10.37256/ccds.5220244756.

19. Machine Vision Based Liquid Level Inspection System Using ISEF Edge Detection Technique (2010). Proceedings of the International Conference and Workshop on Emerging Trends in Technology (ICWET). doi:10.1145/1741906.1742044.

20. OpenCV dokumentacija. Dostupno na: https://docs.opencv.org

12. POPIS SLIKA

Slika 1. Usporedba klasičnih operatora detekcije rubova (Roberts, Sobel, Prewitt, Canny) i transformacije udaljenosti na uzorku boce (Izvor: obrada autora)

Slika 2. Dijagram toka algoritma za detekciju razine tekućine (Izvor: obrada autora)

Slika 3. Tri paradigme korištenja euklidske udaljenosti na istoj boci: lokalna (gradijent boje), globalna (K-means klasteri) i varijacijska (Chan-Vese silueta) (Izvor: obrada autora)

Slika 4. Raznolikost skupa podataka: različit broj boca, jačina osvjetljenja i složenost scene (Izvor: obrada autora)

Slika 5. Sve fotografije skupa podataka (36 slika s ukupno 65 boca) (Izvor: obrada autora)

Slika 6. Primjeri kategorija boca u skupu podataka: prema vrsti boce (prozirna, obojena, staklena, plastična) i prema sadržaju (voda, sok, obojana tekućina) (Izvor: obrada autora)

Slika 7. Primjer ručno označenih referentnih vrijednosti: okvir boce i stvarna razina tekućine (Izvor: obrada autora)

Slika 8. Primjer anotiranog rezultata: obris boce (zeleno), procijenjena razina tekućine i pokazivač ispunjenosti (Izvor: obrada autora)

Slika 9. Ukupni rezultati po algoritmu: odziv, preciznost i srednja apsolutna pogreška razine (Izvor: obrada autora)

Slika 10. Procijenjena naspram stvarne razine punjenja za sve uspješno pronađene boce (Izvor: obrada autora)

Slika 11. Usporedba četiriju algoritama na jednostavnoj sceni (jedna boca, jako osvjetljenje) (Izvor: obrada autora)

Slika 12. Usporedba četiriju algoritama na kompleksnoj sceni (više boca, umjereno osvjetljenje) (Izvor: obrada autora)

Slika 13. Odziv i srednja apsolutna pogreška razine po složenosti scene (Izvor: obrada autora)

Slika 14. Odziv i srednja apsolutna pogreška razine po jačini osvjetljenja (Izvor: obrada autora)

Slika 15. Prosječno vrijeme obrade po slici za pojedini algoritam (Izvor: obrada autora)

13. POPIS TABLICA

Tablica 1. Raspodjela boca u skupu podataka po obilježjima (ukupno 65 boca) (Izvor: obrada autora)

Tablica 2. Ukupni rezultati po algoritmu (65 boca, 36 slika) (Izvor: obrada autora)

Tablica 3. Rezultati po složenosti scene (MAE u postotnim bodovima) (Izvor: obrada autora)